

Nivell 1: Entorn i Ingesta Híbrida (Code-First)

Escenari:

Acabeu d'arribar a l'empresa. L'equip d'Enginyeria de Dades ha deixat els fitxers històrics al Data Lake corporatiu.

La teva primera missió és dissenyar i crear l'entorn de treball. El CTO exigeix professionalitat: no bolcarem dades sense ordre, sinó que implementarem una Arquitectura Medallion.

Exercici 1: Arquitectura de Dades (Lògica vs. Física)

Abans de tocar la consola, has d'entendre la diferència entre allò que dissenyem i allò que construïm:

» **Arquitectura Lògica (Capas de Dades):** És el disseny conceptual. Organitza les dades segons el seu nivell de qualitat (Bronze, Silver, Gold).

» **Implementació Física (Datasets):** És el recurs real a Google Cloud. A BigQuery, utilitzarem Datasets (contenidors) per materialitzar físicament aquestes capas lògiques.

» Tasques:

Implementareu físicament l'arquitectura lògica creant tres Datasets dins d'un mateix projecte per centralitzar la facturació i els permisos.

» Crea un **Nou Projecte** a Google Cloud anomenat:

sprint3-analytics-[el-teu-nom].

Ho pots crear per la UI, però si ho fas per Consola (gcloud CLI) té un plus.

Desde la consola, primer validem que el compte és el correcte, on hem rebut la invitació, i busquem el ID de l'organització que s'ha creat:

```
C:\Users\USUARIO\AppData\Local\Google\Cloud SDK>gcloud auth list
Credentialed Accounts
ACTIVE  ACCOUNT
*       [redacted]@gmail.com

To set the active account, run:
$ gcloud config set account 'ACCOUNT'

C:\Users\USUARIO\AppData\Local\Google\Cloud SDK>gcloud organizations list
DISPLAY_NAME          ID  DIRECTORY_CUSTOMER_ID
bieliki-internet-org  986065437742
```

Amb l'ID, ja podem crear el nou projecte, indicant el nom del projecte (sprint3-analytics-bieldomenech) i on ha d'estar aquest projecte (el ID de l'organització que acabem de buscar, en aquest cas 986065437742). El nom del projecte (i de futurs elements dins d'aquest per mantenir una mateixa metodologia) l'escriurem seguint el format *snake_case* (tot en minúscules i separat per guions baixos):

```
C:\Users\USUARIO\AppData\Local\Google\Cloud SDK>gcloud projects create sprint3-analytics-bieldomenech --organization=986065437742
Create in progress for [https://cloudresourcemanager.googleapis.com/v1/projects/sprint3-analytics-bieldomenech].
Waiting for [operations/create_project.global.7952382078136759813] to finish...done.
Enabling service [cloudapis.googleapis.com] on project [sprint3-analytics-bieldomenech]...
Operation "operations/acat.p2-639836424513-3ede2c6e-55a2-497c-994b-a5815f4a458d" finished successfully.
[environment: untagged] Read more to tag: g.co/cloud/project-env-tag.
```

Selecciona un recurso Proyecto nuevo 

bieliki-internet-org ▼

Recientes Destacados Todos

Nombre	Tipo	ID
▼  bieliki-internet-org	Organización	986065437742
 sprint3-analytics-bieldomenech	Proyecto	sprint3-analytics-bieldomenech 

Amb això, hem aconseguit crear el projecte dins de l'organització.

Un fet important per diferents motius:

Per començar, crear el projecte dins de l'organització fa que la facturació vagi a càrrec de l'empresa. En el cas que el projecte estigués fora, la facturació l'hauria de pagar l'analista. O, si no hi ha un compte de facturació, el projecte es bloquejaria.

Després, s'ha de crear així per temes de jerarquia. El projecte es treballa dins de l'empresa o departament (l'organització). Així, després es poden aplicar polítiques globals per part dels administradors (per exemple, que tots els *datasets* estiguin ubicats en certa ubicació/regió concreta).

Aquesta mateixa jerarquia fa que la gestió d'usuaris sigui més senzilla, en heretar-se/propagar-se (si es vol) de dalt (l'organització) cap avall (projectes, *datasets*, etc) utilitzant la Gestió d'Identitat i d'Accessos (*IAM* per les seves sigles en anglès).

Per demostrar el teu domini total de la plataforma, crearàs cadascun dels *datasets* utilitzant un mètode diferent:

» **Dataset Físic** `sprint3_bronze` → Capa Lògica Bronze (Dades Crudes)

Funció: Dades crues tal com arriben de la font.

Mètode: Utilitza la **Interfície Gràfica (UI)** de BigQuery (fent clics).

Per crear el *dataset* `sprint3_bronze` primer hem de seleccionar el projecte:

Selecciona un recurso Proyecto nuevo 


bieliki-internet-org ▼

Recientes Destacados Todos

Nombre	Tipo	ID
▼  bieliki-internet-org	Organización	986065437742
 sprint3-analytics-bieldomenech	Proyecto	sprint3-analytics-bieldomenech 

Un cop dins del projecte, buscarem al costat del nom del projecte els tres punts verticals i clicarem. En el submenú que apareix, escollirem l'opció **Crear un conjunto de datos**.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol



En la següent finestra que ens apareix, indicarem (com hem dit abans, seguint el format *snake_case*) el nom del *dataset* i l'ubicació d'aquest.

Crear un conjunto de datos

ID del proyecto *

sprint3-analytics-bieldomenech

[Cambiar](#)

ID de conjunto de datos *

sprint3_bronze

Puede incluir letras, números y guiones bajos

Ubicación de los datos

Filtrar | Escribe para filtrar

Multirregiones

US (múltiples regiones en Estados Unidos)

EU (múltiples regiones en la Unión Europea)

África

africa-south1 (Johannesburgo)

América

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Com a ubicació, escollirem la multiregió EU, ja que aquesta opció permet a Google fer una còpia de les dades (redundàcia) en una altra ubicació europea, per la qual cosa en el cas d'una caiguda en algun dels centres de dades, les dades continuarien disponibles (millor resiliència).

Si escollíssim una seu únicament per la seva proximitat com europe-southwest1 (Madrid), l'únic guany que tindriem és en una latència menor, però no seria significativa (la resposta seria uns mil·lisegons més ràpida). Per altre banda, les dades estarien físicament a Madrid, i si hi hagués un problema en aquest centre de dades, les dades potser no estarien plenament disponibles durant la incidència.

També s'ha d'indicar que escollim la multiregió EU degut a que posteriorment hem de carregar unes taules que estan en aquesta ubicació. Si els *datasets* i les taules estan en ubicacions diferents, les consultes posteriors donarien error ja que els *datasets* i les taules "no es veurien".

Crear un conjunto de datos

ID del proyecto *

sprint3-analytics-bieldomenech

[Cambiar](#)

ID de conjunto de datos *

sprint3_silver

Puede incluir letras, números y guiones bajos

Ubicación de los datos

[Filtrar](#) Escribe para filtrar

Multirregiones

US (múltiples regiones en Estados Unidos)

EU (múltiples regiones en la Unión Europea)

África

africa-south1 (Johannesburgo)

América

northamerica-northeast1 (Montreal)

Conjunto de datos externo

The selected region supports the following external dataset types: Cloud Spanner

☐ Vínculo a un conjunto de datos externo [?](#)

Etiquetas

Las etiquetas te ayudan a administrar y aplicar políticas en los recursos. Constan de una clave de etiqueta única y un conjunto de valores de etiqueta. [Más información](#)

[Seleccionar el alcance de las etiquetas](#)

Opciones avanzadas

Encriptación [?](#)

☒ Clave de encriptación administrada por Google
Claves propiedad de Google

☐ Clave de Cloud KMS
Claves propiedad de los clientes



Ahora puedes automatizar la creación de claves de Cloud KMS con Autokey.

[Descartar](#)

[Más información](#)

Crear un conjunto de datos

No distingue mayúsculas de minúsculas

☐ Habilitar los nombres de tablas que no distinguen mayúsculas de minúsculas ?

Intercalación predeterminada ?

Intercalación predeterminada ▼

Vencimiento predeterminado de la tabla

☐ Habilitar el vencimiento de la tabla ?

Máxima antigüedad predeterminada de la tabla Días

Modo de redondeo predeterminado ?

Default Rounding Mode ▼

Modelo de facturación de almacenamiento ?

Modelo de facturación de almacenamiento ▼


Período de viaje en el tiempo ?

Período de viaje en el tiempo ▼

La resta d'opcions les deixarem per defecte, ja que no vincularem amb un *dataset* extern (que faria que el nostre *dataset* bàsicament fos un mirall on només podríem llegir, sense poder escriure i/o modificar), les etiquetes es podran afegir i/o modificar més endavant (si cal), la clau de xifratge és millor la de Google que la que tenim nosaltres (en aquest cas, inexistent).

Com que farem servir el format *snake_case* no fa falta modificar el *case sensitive* que per defecte gestiona Google, la intercalació tampoc la tocarem perquè Google ja gestiona correctament l'ordre i comparació de les cadenes de text, no habilitarem el venciment de les taules per poder gestionar-les d'aquí un temps, el rodoneig predeterminat de Google és l'estàndard financer i científic, el model de facturació tampoc es modificarà perquè utilitza el model lògic que és l'adequat per entorns acadèmics i el període de viatge en el temps (el temps que podem tirar enrere per veure una taula "com estava fa x dies") per defecte és el màxim, que són 7 dies.

I ja tenim creat el *dataset* `sprint3_bronze`:




Tasca S3.01. Introducció a BigQuery i SQL al Núvol

» **Dataset Físic** sprint3_silver → Capa Lògica Silver (Dades Netes)

Funció: Dades netes, tipades i deduplicades.

Mètode: Utilitza codi SQL (CREATE SCHEMA).

Per crear el següent *dataset*, clicarem a **Consulta en SQL** i ens obrirà una pestanya nova on podrem picar el codi SQL corresponent:




The screenshot shows the Google Cloud BigQuery console interface. At the top, there's a search bar and a project selector set to 'sprint3-analytics-bieldomenech'. Below the search bar, there's a 'Buscar recursos de BigQuery' (Search BigQuery resources) input field. To the right, the 'Crear nuevo' (Create new) menu is open, showing options like 'Consulta en SQL' (Query in SQL), 'Notebook', 'Canalización' (Pipeline), 'Preparación de datos' (Data preparation), and 'Lien' (Link). The 'Consulta en SQL' option is highlighted with a red box. Below this, the 'Consulta sin título' (Untitled query) window is shown, containing the SQL code:

```
1 create schema if not exists `sprint3-analytics-bieldomenech.silver`  
2 options(location = "EU");
```

 The status bar at the bottom indicates 'Esta consulta procesará 0 B cuando se ejecute.' (This query will process 0 B when executed).

Es crea l'esquema amb el IF NOT EXISTS per evitar errors de sintaxi en cas que el *dataset* ja estigui creat (permetent que el codi s'executi sense aturar-se). Com que en l'anterior dataset hem indicat la ubicació EU, aquí indicarem la mateixa ubicació per garantir la coherència regional i poder connectar o crear les dades entre capes sense conflictes (si ens fa falta).

Es llença la consulta i es crea el *dataset*:




The screenshot shows the 'Consulta sin título' (Untitled query) window after the SQL code has been executed. The code is:

```
1 create schema if not exists `sprint3-analytics-bieldomenech.sprint3_silver`  
2 options(location = "EU");
```


 The status bar at the bottom indicates 'Se completó la consulta' (Query completed).

I es valida la creació:




» **Dataset Físic** sprint3_gold → Capa Lògica Gold (Dades de Negoci)
Funció: Dades agregades llestes per a informes i panells de control (dashboards).
Mètode: Utilitza Cloud Shell (Línia d'ordres bq).


Per utilitzar Cloud Shell, cliquem a l'icona que activa el Cloud Shell:



Quan s'obre la consola, observem que ens indica en quin projecte estem treballant (apareix el nom del projecte tant en blau en el nom de la pestanya com en groc al prompt). Un cop realitzada aquesta validació visual, procedim a escriure el codi corresponent per crear el tercer *dataset*. Com ens els anteriors *datasets*, com a opcions indicarem la mateixa ubicació per garantir la coherència regional i poder connectar o creuar les dades entre capes sense conflictes (si ens fa falta).




Llencem el procés i ens indica que ja s'ha creat el *dataset*:



Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Recarreguem el contingut del projecte i ja apareix el nou *dataset*:



Tingueu en compte la ubicació de les dades originals per decidir la ubicació física dels tres Datasets.

» **Nota:** Encara que siguin capes lògiques diferents, físicament han de viure a la mateixa regió per poder "parlar" entre elles sense costos de transferència.

Exercici 2: Ingesta en Capa Bronze (Connexió DDL)

Un analista professional automatitza les tasques. Ara que tens la teva arquitectura a punt, poblarem la primera capa (**Bronze**) sense moure les dades originals, creant **Taules Externes** que apuntin al Data Lake.

» Tasca:

Escriu i executa les sentències CREATE EXTERNAL TABLE per connectar els següents fitxers al *dataset* **sprint3_bronze**. Para molta atenció a les "Notes Tècniques", ja que no tots els arxius tenen el mateix format.

Taula	Domini	Ruta al Núvol (URI)	Notes Tècniques
transactions_raw	ERP	gs://bootcamp-data-analytics-public/ERP/transactions.csv	Delimitador: ; (Punt i coma)
companies_raw	ERP	gs://bootcamp-data-analytics-public/ERP/companies.csv	Capçalera: Ignora la 1a fila. Defineix l'esquema manualment perquè tot és text.
american_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/american_users.csv	Estàndard.
european_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/european_users.csv	Estàndard.
credit_cards_raw	CRM	gs://bootcamp-data-analytics-public/CRM/credit_cards.csv	Estàndard.

» Entrega:

El codi SQL utilitzat per a transactions_raw i una captura de pantalla amb les 5 taules creades.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Obrim consulta i escrivim el codi corresponent per crear la taula `transactions_raw`.

Al crear la taula, especificarem el projecte, el *dataset* i el nom de la taula que volem crear amb el format `projecte.dataset.taula`. També especificarem el format de l'arxiu, que el delimitador és un punt i coma (;) i que es salti la primera línia perquè els arxius CSV contenen una fila (la primera) amb capçalera i es carregarien com a dades (provocant després errors de compatibilitat amb els formats de cada camp).

```
Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir]
```

```
1 create or replace external table `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`
2 options (
3   format = 'CSV',
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
5   field_delimiter = ';',
6   skip_leading_rows = 1
7 );
```

✓ Esta consulta procesará 0 B cuando se ejecute.

L'executem i observem que s'ha completat correctament la consulta:

```
Consulta sin título [Ejecutar] [Descargar] [Compartir] [Programa] [Abrir]
```

```
1 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`
2 OPTIONS (
3   format = 'CSV',
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
5   field_delimiter = ';',
6   skip_leading_rows = 1
7 );
```


✓ Se completó la consulta

Validem que la taula s'ha creat:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▼ sprint3_bronze
 - transactions_raw**
 - ▶ sprint3_gold
 - ▶ sprint3_silver

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Ara procedirem a crear les següents 4 taules, i validem que s'hagin creat:



Exercici 3: Càrrega de Dades Locals (Upload)

Falta el catàleg de **Productes**. Aquesta informació no és al Data Lake, utilitza el fitxer *products.csv* de l'sprint 2.


- » Carrega aquest fitxer manualment ("Upload") al dataset sprint3_bronze i crea la taula products_raw.
- » Observa que aquesta serà l'única **Taula Nativa** de moment.

Per crear la taula nativa products_raw ho haurem de fer en dos pasos/procediments diferenciats.

Primer, utilitzant SQL, crearem la taula.


Un cop creada la taula, desde UI haurem de carregar les dades. Aquest pas no es pot fer des de SQL degut a les polítiques de seguretat de Google, que no permeten que l'entorn SQL tingui accés a un ordinador.

Per tant, comencem creant la taula:



Executem el codi:

Tasca S3.01. Introducció a BigQuery i SQL al Núvol




The screenshot shows the BigQuery console interface. At the top, there's a search bar with a magnifying glass icon, followed by the text "Consulta sin título". To the right of this are buttons for "Ejecutar" (Execute), "Descargar" (Download), "Compartir" (Share), and "Proyectos" (Projects). Below the header, a SQL query is displayed in a text area, numbered 1 to 9. The query is a "CREATE OR REPLACE TABLE" statement for a table named "products_raw" in the dataset "sprint3-analytics-bieldomenech.sprint3_bronze". The table has five columns: "id" (STRING), "product_name" (STRING), "price" (STRING), "colour" (STRING), and "weight" (STRING). The query ends with a semicolon. Below the query, a green checkmark icon is followed by the text "Se completó la consulta" (Query completed).

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-bieldomenech.sprint3_bronze.products_raw`  
2 (  
3   id STRING,  
4   product_name STRING,  
5   price STRING,  
6   colour STRING,  
7   weight STRING,  
8   warehouse_id STRING  
9 );
```

✓ Se completó la consulta

Un cop executada, validem que s'ha creat:



The screenshot shows the BigQuery dataset explorer. It displays a tree view of the project "sprint3-analytics-bieldomenech". Under this project, there are several folders: "Repositorios", "Consultas", "Notebooks", "Lienzos de datos", "Preparaciones de datos", "Canalizaciones", and "Conexiones". Below these, there is a folder named "sprint3_bronze". Inside "sprint3_bronze", there are several tables: "american_users_raw", "companies_raw", "credit_cards_raw", "european_users_raw", "products_raw", and "transactions_raw". The "products_raw" table is highlighted with a red rectangle.

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶alizaciones
 - ▶ Conexiones
 - ▼ sprint3_bronze
 - american_users_raw
 - companies_raw
 - credit_cards_raw
 - european_users_raw
 - products_raw**
 - transactions_raw

Un cop creada la taula, procedirem a pujar les dades via UI.

Per fer això, primer seleccionarem el *dataset* `sprint3_bronze` i després polsarem a **Crear tabla**:

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

The screenshot shows the Google Cloud BigQuery console. On the left, a sidebar lists various resources under the project 'sprint3-analytics-bieldomenech'. The 'sprint3-bronze' dataset is highlighted. On the right, the 'sprint3-bronze' dataset page is displayed, showing a list of tables: 'american_users_raw', 'companies_raw', 'credit_cards_raw', 'european_users_raw', 'products_raw', and 'transactions_raw'. A red box highlights the 'Crear tabla' button in the top right corner of the dataset page.

En la següent finestra, configurarem la taula:

A l'origen escollirem l'opció *Subir* (que seria el *UPLOAD*), li indicarem l'arxiu .csv que tenim en local i especificarem el format de l'arxiu (en aquest cas, CSV).

A destí, li indicarem el projecte, el *dataset* i el nom de la taula.

A esquema li marcarem que detecti automàticament l'estructura de la taula.

A les configuracions de particions i cluster ho deixarem tal i com està per defecte, i com abans en els *datasets*, no crearem cap etiqueta.

A les opcions avançades, a la preferència d'escriptura li indicarem que substitueixi la taula ja que la taula ja està creada (l'equivalent al *CREATE OR REPLACE TABLE* de SQL) i així també evitem errors si ho executem més d'una vegada, i li indicarem que s'ha d'ometre la primera filera (com abans al crear les altres taules, ja que la primera filera és la capçalera i no son dades pròpiament dites).

La resta d'opcions, les deixarem per defecte tal i com estan.

The screenshot shows the 'Crear tabla' (Create table) dialog in Google Cloud BigQuery. The dialog is divided into two main sections: 'Fuente' (Source) and 'Destino' (Destination).

Fuente (Source):

- Create table from:** Subir
- Seleccionar archivo *:** N3.Ex.2_products.csv
- Formato del archivo:** CSV

Destino (Destination):

- Proyecto *:** sprint3-analytics-bieldomenech
- Conjunto de datos *:** sprint3-bronze
- Tabla *:** products_raw

At the bottom, there is a note: 'El tamaño máximo del nombre es de 1,024 bytes UTF-8. Se permiten letras, signos, números, conectores, guiones y espacios Unicode.'

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Esquema

☒ Detección automática

El esquema se generará automáticamente.

Configuración de partición

- ☒ Sin particionar
☐ Particionar por tiempo de transferencia
☐ Particionar por campo

Para particionar por campo, primero debes agregar campos al esquema anterior.

Configuración del clúster

Orden del agrupamiento en clústeres

El orden del agrupamiento en clústeres determina la clasificación de los datos. Puede usarse en tablas particionadas y no particionadas.

Etiquetas

Las etiquetas te ayudan a administrar y aplicar políticas en los recursos. Constan de una clave de etiqueta única y un conjunto de valores de etiqueta. [Más información](#)

[Seleccionar el alcance de las etiquetas](#)

Opciones avanzadas

Preferencia de escritura
Reemplaza la tabla

Cantidad de errores permitidos
0

☐ Valores desconocidos

Mapa de caracteres del nombre de la columna
Predeterminado

Delimitador de campos
Coma

Carácter de comilla
Comillas dobles

Coincidencia de columna de origen
Predeterminado

Filas del encabezado que se omitirán
1

Un cop revisat tot, cliquem al botó de **Crear tabla**:

Crear tabla

Fuente

Create table from
Subir

Seleccionar archivo *
N3.Ex.2_products.csv

Formato del archivo
CSV

Destino

Proyecto *
sprint3-analytics-bieldomenech

Conjunto de datos *
sprint3_bronze

Tabla *
products_raw

El tamaño máximo del nombre es de 1,024 bytes UTF-8. Se permiten letras, signos, números, conectores, guiones y espacios Unicode.

Tipo de tabla
Tabla nativa

Esquema

☒ Detección automática

Crear tabla Cancelar

Ens sortirà un avís de que s'ha creat la taula:


Se creó "products_raw".

[Ir a la tabla](#)



Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Validarem que s'ha creat (tot i que ja estava creada, és important revisar-ho per validar que no hagi creat una taula duplicada, etc):



Seleccionarem la taula i clicarem a **Vista previa** (important fer-ho així i no amb una consulta per evitar el cost de la mateixa. **Vista previa** mostra les dades de forma gratuïta al no ser una consulta *per se*) per verificar que la càrrega s'ha realitzat correctament, mentre que una consulta (encara que fos un `SELECT` senzill sense cap operació més) si que realitzaria operacions a nivell intern a BigQuery i suposaria un cost.

The screenshot shows the 'Vista previa' tab of the 'products_raw' table. The table has 15 rows and 7 columns: 'id', 'product_name', 'price', 'colour', 'weight', and 'warehouse_id'. The data is as follows:

Fila	id	product_name	price	colour	weight	warehouse_id
1	7	north of Casterly	63.33	#b7b7b7	0.6	WH-2
2	19	dooku solo	60.33	#3f3f3f	0.6	WH-14
3	31	Lannister	85.02	#3f3f3f	0.6	WH-26
4	43	duel	59.8	#5b5b5b	0.6	WH-38
5	55	Tully maester	3.83	#6d6d6d	0.6	WH-50
6	67	Winterfell	195.94	#1c1c1c	0.6	WH-62
7	79	Direwolf riverlands the	132.86	#b2b2b2	0.6	WH-74
8	91	the duel	59.76	#adadad	0.6	WH-86
9	6	dooku solo	136.6	#c4c4c4	0.8	WH-1
10	18	Karstark warden	148.91	#c4c4c4	0.8	WH-13
11	30	Karstark warden	79.53	#606060	0.8	WH-25
12	42	sith	83.51	#494949	0.8	WH-37
13	54	dooku solo	13.14	#e5e5e5	0.8	WH-49
14	66	mustafar jinn	2.12	#545454	0.8	WH-61
15	78	Karstark warden	178.85	#919191	0.8	WH-73

Results per page: 50 1 - 50 de 1

Exercici 4: Arquitectura i Rendiment. Materialització de Dades (Assistit per IA)

Escenari:

Les consultes sobre el Data Lake van lentes. Has de demostrar al teu mànager la diferència de rendiment entre treballar amb fitxers externs i treballar amb taules natives de BigQuery.

a) Materialització de Dades (Assistit per IA)

» Tasca:

Crea una nova taula anomenada `sprint3_bronze.transactions_raw_native` que sigui una còpia exacta de la teva taula externa `transactions_raw`.

Requisit de "AI-Pair Programming":

No escriguis el codi SQL manualment. Utilitza l'Assistent d'IA (Gemini) integrat a BigQuery (o el xat lateral) per generar la sentència.

» **El Teu Rol:** Ets el responsable de validar que el codi que et dona la IA és correcte abans d'executar-lo.

Prompt Sugerit:

"Write a SQL query to create a new table called `transactions_raw_native` in the `sprint3_bronze` dataset. It should contain all data from the `transactions_raw` table. Please use `CREATE OR REPLACE TABLE` so I don't get errors if I run it more than once."

» Entrega:

Una captura de pantalla on es vegi:

» El prompt que vas escriure a la IA.

» El codi SQL que la IA va generar.

» El resultat de l'execució ("This statement created a new table...").

Comencem clicant a la icona de Gemini:

The screenshot shows the Google Cloud BigQuery console. In the top right corner, the Gemini AI icon is highlighted with a red box. Below the main navigation bar, there's a section titled "Crear nuevo" (Create new) with buttons for "Consulta en SQL", "Notebook", "Notebook con Spark", "Modelo de AA", "Gráfico", "Agente", and "Conversación". Below this, there's a "Recientes" (Recent) table listing various datasets and their modification times.

Nombre visible	Tipo	Hora de última modificación ↓	Proyecto
sprint3_bronze	Conjunto de datos	5 may 2026, 1:46:09 p.m.	sprint3-analytics-bieldomenech
products_raw	Tabla	5 may 2026, 1:11:56 p.m.	sprint3-analytics-bieldomenech
american_users_raw	Tabla	5 may 2026, 11:38:12 a.m.	sprint3-analytics-bieldomenech
credit_cards_raw	Tabla	5 may 2026, 11:13:25 a.m.	sprint3-analytics-bieldomenech
european_users_raw	Tabla	5 may 2026, 11:11:58 a.m.	sprint3-analytics-bieldomenech
companies_raw	Tabla	5 may 2026, 10:55:18 a.m.	sprint3-analytics-bieldomenech
transactions_raw	Tabla	5 may 2026, 10:44:23 a.m.	sprint3-analytics-bieldomenech
sprint3_silver	Conjunto de datos	4 may 2026, 11:30:52 p.m.	sprint3-analytics-bieldomenech
DataSetTEST	Conjunto de datos	4 may 2026, 1:14:57 p.m.	master-anagram-495310-c2

Li demanem que creï una sentència per generar una taula nativa anomenada `transactions_raw_native`, que ha de ser una còpia de la taula externa `transactions_raw`. També especifiquem la ubicació del *dataset* de la taula origen i de la taula destí i indiquem que utilitzi `CREATE OR REPLACE TABLE` per evitar errors si la consulta s'executa diverses vegades.

Welcome to Gemini Cloud Assist

¿En qué podemos ayudarte?

- Analiza el estado de los recursos
- Diseña aplicaciones con ADC
- Comprende y optimiza los costos
- Crea un caso de facturación o un caso de asistencia técnica si tienes un paquete de asistencia

Write an SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset. This table should be native and a copy of the external table transactions_raw that is in the same sprint3_bronze dataset. Use CREATE OR REPLACE TABLE to avoid errors if you run it multiple times.

L'assistent retorna la consulta SQL en dos blocs: el primer explica que la sentència és adequada per crear la taula, i el segon està pensat perquè puguem clicar **Open in Editor** i obrir directament la consulta sense copiar-la manualment.

Gemini can make mistakes. Double check responses, and [use code with caution](#).

Write an SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset. This table should be native and a copy of the external table transactions_raw that is in the same sprint3_bronze dataset. Use CREATE OR REPLACE TABLE to avoid errors if you run it multiple times.

Mostrar razonamiento

You can use the following SQL query to create the native table `transactions_raw_native` as a copy of the external table `transactions_raw`.

I have also prepared this query for you in a new editor tab; click the button below to open it.

```
CREATE OR REPLACE TABLE `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw_native`  
SELECT * FROM `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
```

Generated code may be subject to license restrictions not shown here. Use code with care. [Learn more](#)
Let me know if you need help with anything else!

```
CREATE OR REPLACE TABLE `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw_native`  
SELECT * FROM `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
```


Generated code may be subject to license restrictions not shown here. Use code with care. [Learn more](#)

[Open in Editor](#)


Abans d'executar la consulta, la validem amb un *Dry Run* (la funció que ens permet justament validar sintaxi i estructura SQL sense executar-la, ahora que ens informa del possible cost de la mateixa consulta).

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Copiem el codi, l'enganxem en una pestanya de consulta SQL i comprovem que BigQuery marca la sentència com a correcta amb un tic verd. El *Dry Run* indica que no es processarà cap dada, ja que només està validant sintaxi i estructura.



Un cop validada, executem la consulta i BigQuery crea la taula nativa.



Per verificar que la taula s'ha creat correctament, anem al panell d'exploració, expandim el *dataset* *sprint3_bronze* i seleccionem *transactions_raw_native*. A **Vista previa** comprovem que les dades s'han copiat correctament.

The screenshot shows the BigQuery console's 'Vista previa' (Preview) tab for the 'transactions_raw_native' table. The table has 19 rows and 12 columns. The columns are: id, card_id, business_id, timestamp, amount, declined, product_ids, user_id, and lat. The data is as follows:

id	card_id	business_id	timestamp	amount	declined	product_ids	user_id	lat
1	78F14A51-F321-4CA9-AB42-02...	CcU-4856	2018-10-24 09:46:13 UTC	265.14	0	17, 66, 3	1	40.7036804...
2	00D8F1C6-FF88-4E47-B26B-BC...	CcU-4856	2022-01-25 22:57:15 UTC	272.45	0	81, 94, 95, 66, 64	1	40.7174604...
3	6ED484BC-2DBB-47CF-B77E-12...	CcU-4856	2015-05-08 18:09:41 UTC	233.52	0	85, 56, 55	1	40.7188407...
4	55985941-32AF-490C-BD5A-30...	CcU-4856	2020-06-12 19:22:27 UTC	535.45	0	64, 74, 52, 22	1	40.7064969...
5	4A868EE1-181A-4690-AB53-92...	CcU-4856	2017-10-12 09:30:10 UTC	429.61	0	16, 62, 91	1	40.7195838...
6	3F2720A9-C1C9-4D9B-9FFD-C8...	CcU-4856	2020-08-20 16:55:54 UTC	189.72	0	81, 94, 65	1	40.7132717...
7	7F5C1DBA-F34B-4A4F-BCE9-S1...	CcU-4856	2016-07-04 21:06:10 UTC	6.9	0	95	1	40.7111481...
8	3B5E5817-317E-4C92-A7C9-B5...	CcU-4856	2019-12-04 20:36:55 UTC	384.75	0	4, 57, 2, 79	1	40.7177218...
9	8FA78029-6180-439E-ADA1-F7...	CcU-4856	2021-11-30 02:22:55 UTC	298.56	0	22, 55, 95, 53	1	40.7052669...
10	923E634C-2052-4072-A9F4-0E...	CcU-4856	2019-04-11 02:43:55 UTC	330.7	0	7, 51, 36, 41	1	40.7218733...
11	7A7C6A7C-BA53-4D5C-9A74-9...	CcU-4856	2018-10-21 04:49:45 UTC	267.57	0	100, 64, 52	1	40.7196930...
12	97693F29-668B-4289-8E37-02...	CcU-4856	2015-12-20 18:06:59 UTC	161.33	0	76, 87	1	40.7092072...
13	9C8CE365-C573-4A9A-8F85-A9...	CcU-4856	2020-09-26 12:14:54 UTC	573.13	0	83, 78, 79, 12, 49	1	40.7094684...
14	F3E47D02-CE43-4B87-8C3F-5B...	CcU-4856	2015-11-04 13:01:34 UTC	322.53	0	40, 47, 56	1	40.7075479...
15	7E438CE2-83E0-4C8C-9EA7-0D...	CcU-4856	2018-06-15 18:33:31 UTC	554.76	0	67, 20, 23, 21	1	40.7139257...
16	78C7704E-F5D1-460C-95BF-DB...	CcU-4856	2020-11-02 01:02:53 UTC	294.36	0	99, 80, 34	1	40.7164815...
17	BEE02A09-493E-453D-A0C6-FD...	CcU-4856	2023-12-03 19:53:30 UTC	234.13	0	26, 14, 70, 37	1	40.7033855...
18	338CBAEC-D496-4D2D-9B83-00...	CcU-4856	2018-11-03 03:57:13 UTC	479.39	0	59, 12, 88, 81	1	40.7125347...
19	E505F900-E50F-480B-8A78-7C...	CcU-4856	2019-07-07 03:43:38 UTC	124.04	0	50	1	40.7207374...

Finalment, a **Detalles** podem veure la informació d'emmagatzematge, cosa que confirma que es tracta d'una taula nativa. Si fos una taula externa, apareixeria el camp amb la ruta d'origen en lloc de la informació d'emmagatzematge.

sprint3-analytics-bieldomenech / Datasets / sprint3_bronze / Tables / transactions_raw_native

☆ transactions_raw_native Consulta Chat Abrir en ▾ + Compartir ▾

Esquema **Detalles** Vista previa Explorador de tablas Vista previa Estadísticas Li

Información de la tabla

ID de la tabla	sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw_native
Creado	5 may 2026, 5:25:37 p.m. UTC+2
Última modificación	5 may 2026, 5:25:37 p.m. UTC+2
Vencimiento de la tabla	4 jul 2026, 5:25:37 p.m. UTC+2
Ubicación de los datos	EU
Intercalación predeterminada	
Modo de redondeo predeterminado	ROUNDING_MODE_UNSPECIFIED
No distingue mayúsculas de minúsculas	false
Descripción	
Etiquetas	
Claves primarias	
Etiquetas	

Información de almacenamiento ?

Cantidad de filas	100,000
Total de bytes lógicos	10.87 MB
Bytes lógicos activos	10.87 MB
Bytes lógicos a largo plazo	0 B
Bytes físicos actuales	4.56 MB

b) Auditoria de Costos

» Tasca:

Dissenyar una prova per comparar el cost de llegir una sola columna (ex: id) a la taula externa vs. la taula nativa. Utilitza els Bytes processats i els Bytes facturats per fer la comparació.

» Quant "pesa" la consulta a transactions_raw?

» Quant "pesa" la mateixa consulta a transactions_raw_native?


» Entrega:

Captures del validador mostrant la diferència i una conclusió tècnica.


Tasca S3.01. Introducció a BigQuery i SQL al Núvol

El primer que hem de fer és generar una consulta SQL per tal de que BigQuery llegeixi una columna, tant de la taula externa `transactions_raw` com de la taula nativa `transactions_raw_native`.

Quan escrivim la sentència a BigQuery veiem una diferencia en l'actuació del *Dry Run*, quan la sentència és per la taula externa:



I quan la sentència és per la taula nativa:



Observem que en la consulta a la taula externa, el *Dry Run* mostra que no es processarà cap dada. En canvi, quan fem exactament la mateixa consulta sobre la taula nativa, BigQuery indica que es processaran més de 3 MB.

Això passa perquè BigQuery, en una taula nativa, coneix la mida de cada columna i pot calcular fàcilment quant costarà llegir només `id`.

En canvi, en una taula externa BigQuery no pot saber la mida real de les dades abans d'executar la consulta, perquè els fitxers estan fora del seu sistema intern. Per això el *Dry Run* retorna 0 B.

Quan la consulta s'executa de veritat, BigQuery sí que pot accedir al fitxer extern, però ha de llegir-lo complet, encara que només demanem una columna. Això fa que, previsiblement, el cost real sigui molt més alt que en la taula nativa.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Dit això, llencem les dues consultes per validar les suposicions.

Primer executem la consulta per la taula externa:

Consulta sin título

Ejecutar

Guardar

Descargar

Compartir

Programa

```
1 SELECT id
2 FROM `sprint3_bronze.transactions_raw`;
```

Se completó la consulta

Resultados de la consulta

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Gráfico de ejecuc

ID de trabajo	sprint3-analytics-bieldomenech:EU.bqjob_54c5652b_19df8e1cba2 (Ver detalles de rendimiento)
Usuario	bieliki.internet@gmail.com
Ubicación	EU
Hora de creación	5 may 2026, 6:04:01 p.m. UTC+2
Hora de inicio	5 may 2026, 6:04:01 p.m. UTC+2
Hora de finalización	5 may 2026, 6:04:03 p.m. UTC+2
Duración	1 s
Bytes procesados	12.61 MB
Bytes facturados	13 MB
Milisegundos de ranura	1421
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	Tabla temporal
Motivos por los que no se usó la caché de metadatos	METADATA_CACHING_NOT_ENABLED: sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw
Etiquetas	

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I a continuació, executem la consulta per la taula nativa:

Consulta sin título

Ejecutar

Guardar

Descargar

Compartir

Programa

```
1 SELECT id
2 FROM `sprint3_bronze.transactions_raw_native`;
3
```

Esta consulta procesará 3.62 MB cuando se ejecute.

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Gráfico de ejec

ID de trabajo	sprint3-analytics-bieldomenech:EU.bquxjob_6017c178_19df8e3e8af (Ver detalles de rendimiento)
Usuario	bieliki.internet@gmail.com
Ubicación	EU
Hora de creación	5 may 2026, 6:06:19 p.m. UTC+2
Hora de inicio	5 may 2026, 6:06:20 p.m. UTC+2
Hora de finalización	5 may 2026, 6:06:21 p.m. UTC+2
Duración	1 s
Bytes procesados	3.62 MB
Bytes facturados	10 MB
Milisegundos de ranura	741
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	Tabla temporal
Etiquetas	

Les dues consultes han retornat el mateix resultat:

Resultados de la consulta

Chat

Guardar los resultados

Abrir en

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Gráfico de ejecución

Fila	id
5	4AB68EE1-181A-4690-AB53-92B965C7F89C
6	3F2720A9-C1C9-4D9B-9FFD-C822367D6929
7	7F5C1DBA-F34B-4A4F-BCE9-51B6FF2AD633
8	3B5E6817-317E-4C92-A7C8-B50F7571858D
9	8FA78D29-6180-439E-ADA1-F7764E4C960B
10	923E634C-2052-4072-A9F4-0E0758BE6AA6
11	7A7C6A7C-BA53-4D5C-9A74-963404D87661
12	97693F29-668B-4289-8E37-Q239AA395A97
13	9CBCE365-C573-4A9A-8F85-A91BA2C51934
14	F3E47D02-CE43-4B87-8C3F-SB0D14526F41
15	7E438CE2-83E0-4C8C-9EA7-0DC92F42BAC2

Resultados por página: 50 1 - 50 de 100000

Però la consulta a la taula externa ha processat 12.61 MB, mentre que la mateixa consulta (SELECT id FROM ...) sobre la taula nativa només ha processat 3.62 MB. Això suposa una diferència de 8.99 MB. Dit d'una altra manera, consultar la taula externa fa que el volum de dades processades sigui gairebé quatre vegades superior.

Aquesta diferència es deu al fet que, quan treballem amb una taula externa, BigQuery no pot saber quines parts del fitxer necessita fins que l'obre completament. És com si volguéssim llegir només un paràgraf d'un llibre, però el llibre estigués tancat amb cola: per arribar al paràgraf, cal desenganxar totes les pàgines. En canvi, en una taula nativa, BigQuery té les dades organitzades per columnes i sap exactament on és la informació que li demanem, de manera que només llegeix la columna id i res més.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

En aquest cas, la diferència de cost és “mínima”, però en volums grans de dades, els MB facturats serien molt més elevats en una taula externa, cosa que faria multiplicar el cost de les operacions.

També cal remarcar un punt important que és que els *Bytes facturats* no sempre coincideixen exactament amb els *Bytes processats*, ja que BigQuery aplica la facturació per trams. Això vol dir que, si una consulta processa pocs MB però es manté dins del mateix tram de facturació, el cost serà idèntic. Per aquest motiu, en alguns casos no té sentit invertir hores a optimitzar una consulta per reduir uns quants MB si igualment es facturarà el mateix tram. L'optimització és rellevant quan permet baixar de tram, no quan només redueix el volum processat.

c) El perill del LIMIT

Molts analistes pensen que posar LIMIT 10 redueix el cost de la consulta.

» Tasca:

Fes un SELECT * FROM transactions_raw_native LIMIT 10 sobre la taula externa.

» **Comprovació:** Mira el "Dry Run". Ha baixat el cost respecte a no posar LIMIT? Explica breument per què això és una trampa per a principiants.

La consulta indicada és per a la taula nativa (tot i que falta indicar el *dataset*). Per a la taula externa, la sentència correcta seria:

```
SELECT * FROM sprint3_bronze.transactions_raw LIMIT 10;
```

I per a la taula nativa:

```
SELECT * FROM sprint3_bronze.transactions_raw_native LIMIT 10;
```

En el cas de les taules externes, el *Dry Run* només serveix per validar la sintaxi i l'estructura de la consulta. BigQuery no pot saber la mida real de les dades abans d'executar la consulta perquè els fitxers estan fora del seu sistema intern. Per això, el *Dry Run* no mostra els MB processats.

El cost no baixa en posar LIMIT 10. BigQuery ha de llegir igualment totes les dades abans d'aplicar el LIMIT, de manera que el volum de dades processades és exactament el mateix.


Sembla que demanar només 10 files hauria de costar menys, però BigQuery no pot “llegir només 10 files”. Primer llegeix tota la taula i després retalla el resultat.


En el cas de la taula externa, el *Dry Run* mostra 0 B perquè BigQuery no pot estimar la mida real del fitxer fins que s'executa la consulta. Però això no vol dir que costi menys: quan s'executa de veritat, processa tot el fitxer igualment.

Per poder-ho comparar i veure-ho millor, la sentència amb LIMIT s'ha de provar tant en la taula nativa com en la taula externa. En tots dos casos, el LIMIT no redueix el cost, perquè BigQuery ha de llegir igualment totes les dades abans d'aplicar-lo. Per això el *Dry Run* mostra el mateix volum de dades processades amb o sense LIMIT.



Si executem les sentències tant per a la taula nativa com per a la taula externa, amb o sense LIMIT, veiem que:

En la taula nativa, la consulta amb LIMIT processa 10.87 MB, i sense LIMIT processa exactament el mateix.





En la taula externa, el *Dry Run* no mostra els MB, però el comportament és el mateix: el LIMIT no redueix el cost perquè BigQuery ha de llegir tota la taula abans d'aplicar-lo.



Exercici 5: Adaptació de Sintaxi (Reporting)

El teu cap vol saber quins van ser els **5 dies amb més ingressos de l'any 2021**.

» Repte:

Probablement el camp timestamp és un STRING. Hauràs d'investigar funcions de BigQuery (SUBSTR, CAST, PARSE_TIMESTAMP) per filtrar l'any i agrupar per data correctament.

Revisem el camp timestamp i té el tipus de dada TIMESTAMP.

Farem una select on mostrarem dos columnes, Dates i Total_Vendes. En aquestes dues columnes apareixeran els 5 dies amb més ingressos del 2021.


Ho seleccionarem de la taula nativa transactions_raw_native enlloc de la taula externa transactions_raw, ja que la taula nativa processarà menys dades i per tant redueix el cost de la consulta.

Filtrarem pel camp declined, ja que només hem de considerar les transaccions acceptades. Les transaccions declined (que en la vida real serien refusades o denegades) no generen ingressos i distorsionarien el càlcul del volum real de vendes.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I també filtrarem el timestamp per les dates que estiguin entre el 1 de gener de 2021 i el 31 de desembre de 2021 (ambdós inclosos). Aquest és el patró recomanat per BigQuery per filtrar rangs de dates perquè és un filtre directe sobre la columna i segueix les bones pràctiques recomanades de BigQuery. Tot i que en aquest exercici concret el cost és el mateix que si es fes servir la funció EXTRACT (que és una funció aplicada sobre la columna i no permet la poda de particions), és recomanable seguir el patró correcte.

La sentència SQL que utilitzarem és:




The screenshot shows the BigQuery console interface. At the top, there's a search bar with the text "Consulta sin título". To its right are buttons for "Ejecutar" (Execute), "Guardar" (Save), "Descargar" (Download), and a user icon. Below the search bar, the SQL query is displayed in a code editor:

```
1 select date(timestamp) as Dates, round(sum(amount), 2) as Total_Vendes
2 from `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw_native`
3 where (declined = 0) and (timestamp >= '2021-01-01' and timestamp < '2022-01-01')
4 group by Dates
5 order by Total_Vendes desc
6 limit 5;
```

Below the query, there's a green checkmark icon and the text: "Esta consulta procesará 2.29 MB cuando se ejecute."

I ens retorna els següents resultats:



The screenshot shows the BigQuery console interface with the same SQL query as before. Below the query, there's a green checkmark icon and the text: "Se completó la consulta". Below that, there's a grey button that says "Se está usando la cuota de procesamiento según demanda".

Below the execution status, there's a section titled "Resultados de la consulta". This section contains a table with the following data:

Información del trabajo		Resultados	Visualización	JSON	Detalles de la ejecu
Fila	Dates	Total_Vendes			
1	2021-10-27	11440.81			
2	2021-01-22	11328.84			
3	2021-02-11	11182.16			
4	2021-04-29	11119.01			
5	2021-03-27	10898.51			

Exercici 6: Consultes Complexes

Necessitem un informe que creui dades.

» Tasca:

Llista el nom, país i data de les transaccions realitzades per empreses que van fer operacions entre 100 i 200 euros en alguna d'aquestes dates: 29-04-2015, 20-07-2018 o 13-03-2024.

Farem una consulta on mostrarem tres columnes: Nom_Empresa, Pais i Data_Transaccio. En aquestes columnes apareixeran les empreses que van realitzar transaccions en alguna de les dates sol·licitades i amb un import comprès entre 100 i 200 euros.

Les dades les obtindrem de la taula externa companies_raw i de la taula nativa transactions_raw_native. Utilitzem la taula nativa en lloc de la taula externa transactions_raw perquè la taula nativa processa menys dades i, per tant, redueix el cost de la consulta. Per crear la informació de les empreses amb les seves transaccions, realitzem un JOIN.

Filtrarem pel camp declined, ja que només hem de considerar les transaccions acceptades. Les transaccions declinades (que en un entorn real serien refusades o denegades) no generen ingressos i distorsionarien el càlcul del volum real de vendes.

També filtrarem pel camp amount per descartar totes les transaccions amb imports inferiors a 100 euros o superiors a 200 euros.

Finalment, filtrarem per les tres dates indicades a l'enunciat, utilitzant comparacions directes amb = unides amb OR, tal com recomanen les bones pràctiques per evitar l'ús innecessari de IN.

La sentència SQL que utilitzarem és:

Consulta sin título

Ejecutar

Descargar

Compartir

Programa

Ab

```
1 select c.company_name as Nom_Empresa, c.country as Pais, date(t.timestamp) as Data_Transaccio
2 from `sprint3-analytics-bieldomenech.sprint3-bronze.companies_raw` as c
3 join `sprint3-analytics-bieldomenech.sprint3-bronze.transactions_raw_native` as t
4 on c.company_id = t.business_id
5 where (t.declined = 0) and (t.amount between 100 and 200) and (date(t.timestamp) = '2015-04-29'
6 or date(t.timestamp) = '2018-07-20' or date(t.timestamp) = '2024-03-13');
7
8
```

Esta consulta procesará 3.05 MB cuando se ejecute.

Aquest és el resultat de la consulta executada:

Consulta sin título

Ejecutar

Guardar

Descargar

Compartir

Programa

Abrir en

```
1 select c.company_name as Nom_Empresa, c.country as Pais, date(t.timestamp) as Data_Transaccio
2 from `sprint3-analytics-bieldomenech.sprint3-bronze.companies_raw` as c
3 join `sprint3-analytics-bieldomenech.sprint3-bronze.transactions_raw_native` as t
4 on c.company_id = t.business_id
5 where (t.declined = 0) and (t.amount between 100 and 200) and (date(t.timestamp) = '2015-04-29'
6 or date(t.timestamp) = '2018-07-20' or date(t.timestamp) = '2024-03-13');
7
8
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Chat

Guardar los resultados

Información del trabajo	Resultados	Visualización	JSON	Detalles de la ejecución	Gráfico de ejecución
Fila	Nom_Empresa	Pais	Data_Transaccio		
1	Dictum Eu Corp.	Canada	2015-04-29		
2	Auctor Mauris Vel LLP	United States	2015-04-29		
3	Tempor Diam Institute	Netherlands	2018-07-20		
4	Tempor Diam Institute	Netherlands	2018-07-20		
5	Et Magnis Ltd	Belgium	2018-07-20		
6	Justo Eu Arcu Ltd	Italy	2018-07-20		
7	Netus Et Malesuada Ltd	Netherlands	2018-07-20		
8	Aliquam Erat Volutpat LLP	Italy	2024-03-13		
9	Ac Libero Inc.	United Kingdom	2024-03-13		

Resultados por página: 50 1 - 19 de 19

Nivell 2: Neteja i Transformació (ELT)

Escenari:

Les dades brutes tenen problemes de qualitat (símbols de moneda, usuaris duplicats, dates incorrectes). Actua com a Data Engineer per netejar-ho tot.

Exercici 1: Neteja de Productes (Data Quality)

Crearem la capa neta ("Silver") per als productes. Tens la taula sprint3_bronze.products_raw carregada des del CSV. L'equip de Data Governance et demana crear una taula de productes neta a sprint3_silver.products_clean que compleixi aquestes regles de qualitat:

» **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a product_id. La columna product_name simplifica-la a name.

» **Neteja d'IDs:** El camp warehouse_id té el format antic "WH-4". Elimina el prefix "WH-" i converteix el valor a número enter (INT64).

» **Garantia de Preu:** Assegura't que price és un número (FLOAT64), sense símbols de moneda.

» **Altres columnes:** Conserva el camp weight (pes) tal qual.

Primer hem revisat la taula products_raw, tant a **Esquema** com a **Vista previa**, per veure la taula.

Observem que el camp warehouse_id es STRING i que el camp price es FLOAT.

☆ products_raw Consulta Chat /

Esquema Detalles Vista previa Explorador de t

Filtro Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	
☐	id	INTEGER	NULLABLE	-
☐	product_name	STRING	NULLABLE	-
☐	price	FLOAT	NULLABLE	-
☐	colour	STRING	NULLABLE	-
☐	weight	FLOAT	NULLABLE	-
☐	warehouse_id	STRING	NULLABLE	-

També observem que el camp warehouse_id té diferents nomenclatures WH- i WH-, i que el camp price només té números, no hi ha el símbol del dolar \$.

☆ products_raw Consulta Chat Abrir en ▾ + Compartir ▾ Copiar Instant

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadísticas Linaje Perfil

Fila	id	product_name	price	colour	weight	warehouse_id
1	7	north of Casterly	63.33	#b7b7b7	0.6	WH-2
2	19	dooku solo	60.33	#3f3f3f	0.6	WH-14
3	31	Lannister	85.02	#3f3f3f	0.6	WH-26
4	43	duel	59.8	#5b5b5b	0.6	WH-38
5	55	Tully maester	3.83	#6d6d6d	0.6	WH-50
6	67	Winterfell	195.94	#1c1c1c	0.6	WH-62
7	79	Direwolf riverlands the	132.86	#b2b2b2	0.6	WH-74
8	91	the duel	59.76	#adadad	0.6	WH-86
9	6	dooku solo	136.6	#c4c4c4	0.8	WH-1
10	18	Karstark warden	148.91	#c4c4c4	0.8	WH-13
11	30	Karstark warden	79.53	#606060	0.8	WH-25
12	42	sith	83.51	#494949	0.8	WH-37
13	54	dooku solo	13.14	#e5e5e5	0.8	WH-49

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Amb tot això, decidim crear una sentència on es faran tots els canvis alhora. Es decideix crear una sola sentència perquè així BigQuery només llegirà una sola vegada la taula, en canvi si es fan els canvis en diferents sentències, BigQuery ha de llegir la taula diverses vegades, la qual cosa provoca més MB processats i per tant més cost.

Aquesta sentència (que crearà la taula `products_clean` al *dataset* `sprint3_silver` a partir de la taula `products_raw` del *dataset* `sprint3_bronze`) forma part del procés ELT (Extract-Load-Transform) i té com a objectiu netejar i estandarditzar les dades provinents del CSV original. A continuació s'explica cada part de manera entenedora:

El `CREATE OR REPLACE TABLE ... AS SELECT ...` crea una nova taula `products_clean` amb les dades ja netes. Si la taula ja existia, es reemplaça automàticament. Això garanteix que disposem d'una versió actualitzada i coherent de les dades.

El camp `id` és ambigu, i per fer-lo més descriptiu i coherent es renombra a `product_id` amb un `id` as `product_id`.


El camp `product_name` és redundant, de manera que es simplifica per fer-lo més clar a `name` amb un `product_name` as `name`.

La neteja del camp `warehouse_id` consta de dos parts.

Per una banda, els valors venen amb diferents tipus de formats (`WH-4`, `WH4`) inconsistents que teòricament representen el mateix valor. Amb la funció `REGEXP_REPLACE` identifiquem el prefix `WH` (amb un o més guions), extraïem la part numèrica final i substituïm tot el valor pel número.

Amb el `CAST(... as INT64)` convertim aquest valor en un enter.

La resta de camps com `price`, `weight` i `colour` com que ja estan bé tal i com estan, simplement es copien a la nova taula sense més modificacions.



The screenshot shows the BigQuery console interface. At the top, there's a search bar and a title "Consulta sin título". To the right of the title are buttons for "Ejecutar" (Execute), "Guardar" (Save), "Descargar" (Download), and "Compartir" (Share). Below the toolbar, a SQL query is displayed in a text area, numbered 1 through 8. The query creates or replaces a table named `products_clean` in the `sprint3-silver` dataset, selecting data from the `products_raw` table in the `sprint3-bronze` dataset. The query includes a `CAST` operation to convert the `warehouse_id` to `INT64` using `REGEXP_REPLACE`. At the bottom, a green checkmark icon is followed by the text: "Esta consulta procesará 5.62 KB cuando se ejecute."

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.products_clean` as
2 select id as product_id,
3 product_name as name,
4 cast(regex_replace(warehouse_id, r'^WH-+([0-9]+)$', r'\1') as int64) as warehouse_id,
5 price,
6 weight,
7 colour
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.products_raw`;
```

✓ Esta consulta procesará 5.62 KB cuando se ejecute.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I aquest és el resultat:

The screenshot shows the Google Cloud BigQuery console interface. At the top, there's a header with a search icon, the title 'Consulta sin título', and buttons for 'Ejecutar', 'Guardar', 'Descargar', and 'Compartir'. Below the header, the SQL query is displayed in a text area with line numbers 1 through 8. The query is a 'create or replace table' statement that selects data from 'sprint3-bronze.products_raw' and casts it into a new table 'sprint3-silver.products_clean'. Below the query, a green checkmark icon indicates 'Se completó la consulta'. A grey bar below that states 'Se está usando la cuota de procesamiento según demanda'. The main section is titled 'Resultados de la consulta' and contains a tabbed interface with 'Información del trabajo', 'Resultados' (selected), 'Detalles de la ejecución', and 'Gráfico de ejecución'. Under the 'Resultados' tab, an information icon and text state: 'Esta declaración creó una nueva tabla con el nombre products_clean.'

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.products_clean` as
2 select id as product_id,
3 product_name as name,
4 cast(regex_replace(warehouse_id, r'^WH-+([0-9]+)$', r'\1') as int64) as warehouse_id,
5 price,
6 weight,
7 colour
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.products_raw`;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre products_clean.

Validem que s'ha creat la taula:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▶ sprint3_gold
 - ▼ sprint3_silver
 - ▶ **products_clean**

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I validarem tant els canvis en els camps i els valors com la creació des de **Esquema** i **Vista previa**:

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / products_clean

☆

products_clean

🔍

Consulta

💬

Chat

📄

Abrir en ▾

👤

Compartir ▾

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísti

Filtro Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Ir
☐	product_id	INTEGER	NULLABLE	-	-	-
☐	name	STRING	NULLABLE	-	-	-
☐	warehouse_id	INTEGER	NULLABLE	-	-	-
☐	price	FLOAT	NULLABLE	-	-	-
☐	weight	FLOAT	NULLABLE	-	-	-
☐	colour	STRING	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / products_clean

☆

products_clean

🔍

Consulta

💬

Chat

📄

Abrir en ▾

👤

Compartir ▾

📄

Copiar

📄

Instantánea

🗑️

Borrar

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Linaje

Perfil de datos

Calidad d

Fila	product_id	name	warehouse_id	price	weight	colour	
1	7	north of Casterly	2	63.33	0.6	#b7b7b7	
2	31	Lannister	26	85.02	0.6	#3f3f3f	
3	79	Direwolf riverlands the	74	132.86	0.6	#b2b2b2	
4	91	the duel	86	59.76	0.6	#adadad	
5	67	Winterfell	62	195.94	0.6	#1c1c1c	
6	55	Tully maester	50	3.83	0.6	#6d6d6d	
7	19	dooku solo	14	60.33	0.6	#3f3f3f	
8	43	duel	38	59.8	0.6	#5b5b5b	
9	6	dooku solo	1	136.6	0.8	#c4c4c4	
10	54	dooku solo	49	13.14	0.8	#e5e5e5	
11	18	Karstark warden	13	148.91	0.8	#c4c4c4	
12	90	Winterfell	85	39.73	0.8	#757575	
13	66	mustafar jinn	61	2.12	0.8	#545454	
14	78	Karstark warden	73	178.85	0.8	#919191	

Resultados por página: 50 ▾ 1 – 50 de 100

Exercici 2: Creació de Transaccions Netes (Capa Silver)

Escenari:

La taula `transactions_raw` (Bronze) és insegura: l'import (amount) podria tenir lletres, les coordenades podrien fallar i la data és un text difícil de filtrar. Crearem la taula definitiva `sprint3_silver.transactions_clean` que garanteixi el següent.

- » **Estandardització de Noms:** La columna original `id` és ambigua; reanomena-la a `transaction_id`.
- » **Robustesa en Imports:** Utilitza `SAFE_CAST` al camp `amount`. Si falla, substitueix-lo per 0 (usant `IFNULL`).
- » **Dates Reals:** Converteix el camp `timestamp` (que és `STRING`) a tipus `TIMESTAMP` real.
- » **Coordenades:** Assegura que `lat` i `longitude` siguin `FLOAT64` (utilitza `SAFE_CAST` per seguretat).
- » **Resta de camps:** Mantén-los igual.

En aquest exercici es crea la taula `transactions_clean` al *dataset* `sprint3_silver` a partir de la taula `transactions_raw` del *dataset* `sprint3_bronze`. Igual que en l'exercici anterior, es decideix aplicar totes les transformacions en una sola sentència SQL. D'aquesta manera BigQuery només llegeix la taula d'origen una vegada, fet que redueix el cost i garanteix que totes les neteges s'apliquen de forma coherent.

El camp `id` es renombra a `transaction_id` perquè el nom original és ambigu i no indica clarament que es tracta de l'identificador de la transacció. Aquest canvi segueix les bones pràctiques d'estandardització de noms dins del procés ELT.

El camp `amount` pot contenir valors incorrectes o fins i tot lletres. Per evitar errors, s'utilitza la funció `SAFE_CAST`, que intenta convertir el valor a número sense provocar fallades. Si la conversió no és possible, el resultat és `NULL`. Per evitar imports buits, s'aplica `IFNULL(..., 0)` per substituir qualsevol valor no vàlid per 0. Això garanteix que totes les transaccions tenen un import numèric vàlid.

El camp `timestamp` arriba com a text i és difícil de filtrar o ordenar. Per aquest motiu es converteix a un tipus `TIMESTAMP` real amb `SAFE_CAST`, assegurant que totes les dates quedin en un format adequat per a consultes temporals, com ordenar transaccions o calcular intervals.

Els camps `lat` i `longitude` també poden contenir valors incorrectes. Per garantir que siguin numèrics, s'utilitza `SAFE_CAST` a `FLOAT64`. Si algun valor no és vàlid, es converteix en `NULL`, evitant errors en consultes posteriors que utilitzin coordenades.

La resta de camps (`user_id`, `product_ids` i `declined`) ja arriben en bon estat i simplement es copien a la taula sense modificacions addicionals.


Dit això, carreguem la sentència:

```
Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir]
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as
2 select id as transaction_id,
3 ifnull(safe_cast(amount as float64), 0) as amount,
4 safe_cast(timestamp as timestamp) as timestamp,
5 safe_cast(lat as float64) as lat,
6 safe_cast(longitude as float64) as longitude,
7 card_id,
8 business_id,
9 product_ids,
10 user_id,
11 declined
12 from `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
13
```

✓ Esta consulta procesará 0 B cuando se ejecute.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Executem la consulta:



The screenshot shows the BigQuery console interface. At the top, there's a search bar and a title 'Consulta sin título'. To the right are buttons for 'Ejecutar', 'Guardar', 'Descargar', and 'Compartir'. Below this is a SQL query editor with the following code:

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as
2 select id as transaction_id,
3 ifnull(safe_cast(amount as float64), 0) as amount,
4 safe_cast(timestamp as timestamp) as timestamp,
5 safe_cast(lat as float64) as lat,
6 safe_cast(longitude as float64) as longitude,
7 card_id,
8 business_id,
9 product_ids,
10 user_id,
11 declined
12 from `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
13
```

Below the query editor, a green checkmark icon and the text 'Se completó la consulta' indicate that the query was executed successfully.

Resultados de la consulta

Chi

Información del trabajo

Resultados

Detalles de la ejecución

Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre transactions_clean.

Validem que s'ha creat la taula:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▶ sprint3_gold
 - ▼ sprint3_silver
 - ▶ products_clean
 - ▶ transactions_clean

I validarem tant els canvis en els camps i els valors com la creació des de **Esquema i Vista previa**:

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / transactions_clean

☆ transactions_...

Consulta

Chat

Abrir en ▾

Compartir ▾

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Filtro

Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Indice
☐	transaction_id	STRING	NULLABLE	-	-	-
☐	amount	FLOAT	NULLABLE	-	-	-
☐	timestamp	TIMESTAMP	NULLABLE	-	-	-
☐	lat	FLOAT	NULLABLE	-	-	-
☐	longitude	FLOAT	NULLABLE	-	-	-
☐	card_id	STRING	NULLABLE	-	-	-
☐	business_id	STRING	NULLABLE	-	-	-
☐	product_ids	STRING	NULLABLE	-	-	-
☐	user_id	INTEGER	NULLABLE	-	-	-
☐	declined	INTEGER	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / transactions_clean

☆ transactions_...

Consulta

Chat

Abrir en ▾

Compartir ▾

Copiar

Instantánea

Borrar

↗

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Linaje

Perfil de datos

Calidad de los datos

Fila	transaction_id	amount	timestamp	lat	longitude	card_id	business_id
1	00D8F1C6-FF88-4E47-B26B-BC...	272.45	2022-01-25 22:57:15 UTC	40.7174604...	-73.9960221...	CcU-4856	b-2314
2	6ED484BC-2DBB-47CF-B77E-12...	233.52	2015-05-08 18:09:41 UTC	40.7188407...	-74.0131030...	CcU-4856	b-2242
3	55985941-32AF-490C-BD5A-30...	535.45	2020-06-12 19:22:27 UTC	40.7064969...	-74.0081135...	CcU-4856	b-2390
4	3F2720A9-C1C9-4D9B-9FFD-C8...	189.72	2020-08-20 16:55:54 UTC	40.7132717...	-74.0044826...	CcU-4856	b-2390
5	BEE02A09-493E-453D-A0C6-FD...	234.13	2023-12-03 19:53:30 UTC	40.7033855...	-73.9970408...	CcU-4856	b-2526
6	CD8AB616-4E77-4570-9233-7B...	233.84	2024-01-11 18:37:25 UTC	40.7185186...	-74.0005259...	CcU-4856	b-2394
7	02800DB7-FAF0-4602-B28C-76F...	212.74	2016-09-22 02:43:55 UTC	40.7222170...	-73.9985114...	CcU-4856	b-2494
8	1EDDC7AC-D3CA-440B-A048-3...	254.46	2024-11-15 14:48:20 UTC	40.7069930...	-74.0054961...	CcU-4856	b-2426
9	97693F29-668B-4289-8E37-023...	161.33	2015-12-20 18:06:59 UTC	40.7092072...	-74.0042491...	CcU-4856	b-2422
10	4AB68EE1-181A-4690-AB53-92...	429.61	2017-10-12 09:30:10 UTC	40.7195838...	-74.0063626...	CcU-4856	b-2338
11	7F5C1DBA-F34B-4A4F-BCE9-51...	6.9	2016-07-04 21:06:10 UTC	40.7111481...	-74.0068619...	CcU-4856	b-2294
12	78F14A51-F321-4CA9-AB42-02...	265.14	2018-10-24 09:46:13 UTC	40.7036804...	-74.0080139...	CcU-4856	b-2282
13	7DCC175C-4ACA-47EB-9F7D-3...	277.83	2019-03-04 13:48:19 UTC	40.7093088...	-74.0115485...	CcU-4856	b-2494
14	78C7704E-F5D1-460C-958F-DB...	294.36	2020-11-02 01:02:53 UTC	40.7164815...	-74.0119302...	CcU-4856	b-2334

Resultados por página: 50 ▾ 1 – 50 de 100000 |<

Exercici 3: Unificació d'Usuaris (UNION)

Tenim els usuaris fragmentats per regió.

» Tasca:

Crea la taula `sprint3_silver.users_combined`. Utilitza `UNION ALL` per unificar els usuaris dels EUA i Europa en una única llista mestra. Afegeix una columna calculada `origin` per saber d'on venen.

» **Estandardització de Noms:** La columna original `id` és ambigua; reanomena-la a `user_id`.

En aquest exercici es crea la taula `users_combined` al *dataset* `sprint3_silver` a partir de les taules `american_users_raw` i `european_users_raw` ubicades al *dataset* `sprint3_bronze`. L'objectiu és unificar tots els usuaris en una única taula que permeti treballar amb una llista mestra d'usuaris independentment de la seva procedència.

Per combinar les dues taules s'utilitza la instrucció `UNION ALL`, que permet ajuntar registres de diferents taules sense eliminar cap fila. Aquesta operació és adequada perquè cada usuari és únic i no hi ha risc de duplicats. Igual que en els exercicis anteriors, es decideix aplicar totes les transformacions en una sola sentència SQL per reduir el cost i garantir coherència en el procés ELT.

El camp `id` es renombra a `user_id` perquè el nom original és ambigu i no indica clarament que es tracta de l'identificador de l'usuari. La resta de camps es mantenen igual, ja que provenen de taules del *dataset* `sprint3_bronze` que ja han estat validades prèviament.

S'afegeix una columna calculada anomenada `origin` per indicar la procedència de cada usuari. Tot i que l'enunciat es refereix als "EUA", en revisar el CSV original s'observa que els usuaris de la taula `american_users_raw` provenen de diferents països americans. Per aquest motiu, s'utilitza el valor "America" per als usuaris d'aquesta taula i "Europe" per als usuaris de la taula `european_users_raw`, reflectint millor la realitat de les dades.

El resultat és una taula unificada, clara i estandarditzada, que permet treballar amb tots els usuaris de manera conjunta en les capes analítiques posteriors.

Dit això, carreguem la sentència:



```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.users_combined` as
2 select id as user_id,
3 name,
4 surname,|
5 phone,
6 email,
7 birth_date,
8 country,
9 city,
10 postal_code,
11 address,
12 'America' as origin
13 from `sprint3-analytics-bieldomenech.sprint3_bronze.american_users_raw`
14
15 union all
16
17 select id as user_id,
18 name,
19 surname,
20 phone,
21 email,
22 birth_date,
23 country,
24 city,
25 postal_code,
26 address,
27 'Europe' as origin
28 from `sprint3-analytics-bieldomenech.sprint3_bronze.european_users_raw`;
29
```

✓ Esta consulta procesará 0 B cuando se ejecute.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I l'executem.

The screenshot shows the Google BigQuery web interface. At the top, there's a toolbar with buttons for 'Ejecutar' (Execute), 'Guardar' (Save), 'Descargar' (Download), and 'Compartir' (Share). Below the toolbar, the SQL query is displayed in a text editor. The query is a 'create or replace table' statement that combines data from two tables: 'american_users_raw' and 'european_users_raw'. The query selects various user attributes like id, name, surname, phone, email, birth_date, country, city, postal_code, and address, and adds an 'origin' column with values 'America' and 'Europe'. Below the query editor, a green checkmark icon and the text 'Se completó la consulta' (Query completed) indicate successful execution. Underneath, the 'Resultados de la consulta' (Query results) section is visible, with tabs for 'Información del trabajo', 'Resultados', 'Detalles de la ejecución', and 'Gráfico de ejecución'. The 'Resultados' tab is active, showing a message: 'Esta declaración creó una nueva tabla con el nombre users_combined.' (This statement created a new table with the name users_combined.).

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.users_combined` as
2 select id as user_id,
3 name,
4 surname,
5 phone,
6 email,
7 birth_date,
8 country,
9 city,
10 postal_code,
11 address,
12 'America' as origin
13 from `sprint3-analytics-bieldomenech.sprint3_bronze.american_users_raw`
14
15 union all
16
17 select id as user_id,
18 name,
19 surname,
20 phone,
21 email,
22 birth_date,
23 country,
24 city,
25 postal_code,
26 address,
27 'Europe' as origin
28 from `sprint3-analytics-bieldomenech.sprint3_bronze.european_users_raw`;
29
```

Se completó la consulta

Resultados de la consulta

Información del trabajo **Resultados** Detalles de la ejecución Gráfico de ejecución

i Esta declaración creó una nueva tabla con el nombre users_combined.

Validem que s'ha creat la taula:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▶ sprint3_gold
 - ▼ sprint3_silver
 - ▶ products_clean
 - ▶ transactions_clean
 - ▶ **users_combined**

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I validarem tant els canvis en els camps i els valors com la creació des de **Esquema** i **Vista previa**:

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / users_combined

☆ users_combin...

🔍 Consulta

💬 Chat

Abrir en ▾

+👤 Compartir ▾

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadístic

Filtro

Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Int
☐	user_id	INTEGER	NULLABLE	-	-	-
☐	name	STRING	NULLABLE	-	-	-
☐	surname	STRING	NULLABLE	-	-	-
☐	phone	STRING	NULLABLE	-	-	-
☐	email	STRING	NULLABLE	-	-	-
☐	birth_date	STRING	NULLABLE	-	-	-
☐	country	STRING	NULLABLE	-	-	-
☐	city	STRING	NULLABLE	-	-	-
☐	postal_code	STRING	NULLABLE	-	-	-
☐	address	STRING	NULLABLE	-	-	-
☐	origin	STRING	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / users_combined

☆ users_combin...

🔍 Consulta

💬 Chat

Abrir en ▾

+👤 Compartir ▾

📄 Copiar

📄 Instantánea

🗑️ Borrar

🔗

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Linaje

Perfil de datos

Calidad de los dato

Fila	user_id	name	surname	phone	email	birth_date
32	237	Drake	Walsh	048-338-9721	libero.integer@google.edu	Jan 22, 1984
33	1382	Rpmoqu	Prftlkms	+51-643-9685	rpmoqu.prftlkms@example.com	Dec 24, 1969
34	1829	Focrcn	Kdcceuol	+75-553-6878	focrcn.kdcceuol@example.com	Oct 22, 1969
35	3932	Amhiax	Irmqozry	+39-894-1178	amhiax.irmqozry@example.com	Jul 6, 1986
36	4278	Lwcdof	Isruystb	+48-189-2140	lwcdof.isruystb@example.com	Dec 19, 1955
37	2327	Pkvvjv	Yjdvenuz	+31-958-3810	pkvvjv.yjdvenuz@example.com	Aug 15, 1962
38	895	Pimesu	Jzyalbpd	+36-755-3737	pimesu.jzyalbpd@example.com	May 14, 1998
39	2419	Akezxe	Gyjheyuv	+66-453-6021	akezxe.gyjheyuv@example.com	Apr 21, 1963
40	4281	Btixrf	Lqrkuplk	+81-202-4145	btixrf.lqrkuplk@example.com	Sep 12, 1966
41	1252	Ndfnwn	Mctopyxw	+53-277-2471	ndfnwn.mctopyxw@example.co...	Feb 19, 1982
42	2795	Tecfzz	Neslcjiq	+64-714-9985	tecfzz.neslcjiq@example.com	Jul 18, 1956
43	3553	Evblkj	Prkykddd	+81-857-9762	evblkj.prkykddd@example.com	Mar 5, 1984
44	3808	Blmbve	Dcpfrpgf	+57-227-9971	blmbve.dcpfrpgf@example.com	Jun 21, 1958

Resultados por página: 50 ▾ 1 – 50 de 5000 |< >

Exercici 4: Materialització de Companyies i Targetes de Crèdit

Escenari:

Per completar el model de dades a la capa Silver, ens falten dues dimensions clau que actualment depenen de fitxers CSV externs: **Companyies** i **Targetes de Crèdit**. No podem dependre de fitxers solts per a l'anàlisi final. Hem d'importar aquestes dades a taules natives (Silver) i aprofitar per corregir formats.

Tasques:

- » 1. Crea la taula `sprint3_silver.companies_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).
 - » 2. Crea la taula `sprint3_silver.credit_cards_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).
- Si cal, reanomenar l'id segons correspongui.


En aquest exercici es creen dues taules natives al *dataset* `sprint3_silver` a partir de les taules externes `companies_raw` i `credit_cards_raw` ubicades al *dataset* `sprint3_bronze`. L'objectiu és deixar de dependre de fitxers CSV externs i consolidar les dades en taules natives de BigQuery, que són més eficients i fiables per a l'anàlisi. Aquest procés forma part del flux ELT, on primer es carreguen les dades tal com arriben i després es transformen en capes superiors.

La taula `companies_clean` es crea copiant directament totes les columnes de la taula `companies_raw` del *dataset* `sprint3_bronze`. No cal aplicar cap transformació perquè les dades del CSV ja són consistents i no hi ha cap camp ambigu. L'únic canvi rellevant és que la taula resultant passa a ser nativa, cosa que permet utilitzar-la en consultes analítiques sense dependre del fitxer original.

En el cas de `credit_cards_clean`, també es copien totes les columnes tal com estan, però es renombra el camp `id` a `card_id` per evitar ambigüitats i mantenir coherència amb la resta del model de dades. La resta de camps es mantenen igual, incloent `expiring_date`, que es conserva en format text perquè l'enunciat indica que les dades s'han de copiar sense modificar-les.

El resultat són dues taules al *dataset* `sprint3_silver` natives, coherents i preparades per ser utilitzades en les següents etapes del projecte, sense dependències externes i amb una estructura clara i estandarditzada.

Dit això, carreguem la sentència per crear la taula `companies_clean`:



The screenshot shows the BigQuery console interface. At the top, there's a search bar with the text "Consulta sin título". To its right are buttons for "Ejecutar" (Execute), "Guardar" (Save), "Descargar" (Download), and "Compartir" (Share). Below this, a SQL query is entered in a text area:

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.companies_clean` as
2 select company_id,
3        company_name,
4        phone,
5        email,
6        country,
7        website
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.companies_raw`;
9
```

At the bottom, a green checkmark icon is followed by the text: "Esta consulta procesará 0 B cuando se ejecute."

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Aquest és el resultat de la consulta executada:

 Consulta sin título Ejecutar Guardar Descargar Compartir

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.companies_clean` as
2 select company_id,
3        company_name,
4        phone,
5        email,
6        country,
7        website
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.companies_raw`;
9
```

 Se completó la consulta

Resultados de la consulta

Información del trabajo **Resultados** Detalles de la ejecución Gráfico de ejecución

 Esta declaración creó una nueva tabla con el nombre companies_clean.

Validem que s'ha creat la taula:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▶ sprint3_gold
 - ▼ sprint3_silver
 - companies_clean**
 - products_clean
 - transactions_clean
 - users_combined

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I validarem tant els canvis en els camps i els valors com la creació des de **Esquema** i **Vista previa**:

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / companies_clean

☆

companies_cl...

🔍

Consulta

💬

Chat

🔗

Abrir en ▾

👤

Compartir ▾

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

≡

Filtro

Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Inter
☐	company_id	STRING	NULLABLE	-	-	-
☐	company_name	STRING	NULLABLE	-	-	-
☐	phone	STRING	NULLABLE	-	-	-
☐	email	STRING	NULLABLE	-	-	-
☐	country	STRING	NULLABLE	-	-	-
☐	website	STRING	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / companies_clean

☆

companies_cl...

🔍

Consulta

💬

Chat

🔗

Abrir en ▾

👤

Compartir ▾

📄

Copiar

📷

Instantánea

🗑️

Borrar

Esquema

Detalles

Vista previa

Explorador de tablas

Vista previa

Estadísticas

Linaje

Perfil de datos

Calidad de l

Fila	company_id	company_name	phone	email	country
1	b-2446	Risus Associates	04 25 82 54 31	egestas.ligula.nullam@google.e...	Australia
2	b-2226	Magna A Neque Industries	04 14 44 64 62	risus.donec.nibh@icloud.org	Australia
3	b-2282	Pretium Neque Corp.	07 77 48 55 28	eleifend.nec.malesuada@proto...	Australia
4	b-2334	Amet Institute	06 33 40 21 33	nullam.lobortis.quam@outlook....	Australia
5	b-2534	Mattis Foundation	06 74 03 95 74	sed@google.couk	Australia
6	b-2498	Metus Vitae Associates	08 25 44 40 66	ad@protonmail.com	Australia
7	b-2462	Pede Ultrices Ltd	04 52 40 26 17	justo.proin@yahoo.com	Belgium
8	b-2598	Aliquam Iaculis Lacus Corp.	04 43 07 91 26	dictum@aol.org	Belgium
9	b-2590	Euismod Mauris Institute	02 13 69 54 85	vivamus.molestie@icloud.ca	Belgium
10	b-2314	A Institute	03 34 91 68 65	metus.aliquam@google.edu	Belgium
11	b-2514	Cras Consulting	07 50 10 85 63	sed.consequat@google.ca	Belgium
12	b-2594	Et Magnis Ltd	03 53 76 11 76	dapibus.ligula@protonmail.net	Belgium
13	b-2274	Sed LLC	01 63 16 26 52	at@outlook.com	Belgium
14	b-2258	Vestibulum Lorem PC	02 02 87 33 40	aenean massa.intener@aol.net	Belgium

Resultados por página: 50 ▾ 1 – 50 de 100

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Ara procedim a carregar la sentència per crear `credit_cards_clean`:

Consulta sin título

Ejecutar Guardar Descargar Compartir

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.credit_cards_clean` as
2 select id as card_id,
3 user_id,
4 iban,
5 pan,
6 pin,
7 cvv,
8 track1,
9 track2,
10 expiring_date
11 from `sprint3-analytics-bieldomenech.sprint3_bronze.credit_cards_raw`;
12
```

✓ Esta consulta procesará 0 B cuando se ejecute.

Aquest és el resultat que confirma la creació.

Consulta sin título

Ejecutar Guardar Descargar Compartir

```
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.credit_cards_clean` as
2 select id as card_id,
3 user_id,
4 iban,
5 pan,
6 pin,
7 cvv,
8 track1,
9 track2,
10 expiring_date
11 from `sprint3-analytics-bieldomenech.sprint3_bronze.credit_cards_raw`;
12
```

✓ Se completó la consulta

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

❗ Esta declaración creó una nueva tabla con el nombre `credit_cards_clean`.

Validem que s'ha creat la taula:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▶ sprint3_gold
 - ▼ sprint3_silver
 - ▶ companies_clean
 - ▶ **credit_cards_clean**
 - ▶ products_clean
 - ▶ transactions_clean
 - ▶ users_combined

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I validarem tant els canvis en els camps i els valors com la creació des de **Esquema** i **Vista previa**:

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / credit_cards_clean

credit_cards_... Consulta Chat Abrir en ▾ + Compartir ▾

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadística

Filtro Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Inte
☐	card_id	STRING	NULLABLE	-	-	-
☐	user_id	INTEGER	NULLABLE	-	-	-
☐	iban	STRING	NULLABLE	-	-	-
☐	pan	STRING	NULLABLE	-	-	-
☐	pin	STRING	NULLABLE	-	-	-
☐	cvv	STRING	NULLABLE	-	-	-
☐	track1	STRING	NULLABLE	-	-	-
☐	track2	STRING	NULLABLE	-	-	-
☐	expiring_date	STRING	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_silver / Tables / credit_cards_clean

credit_cards_... Consulta Chat Abrir en ▾ + Compartir ▾ Copiar Instantánea Borrar

Esquema Detalles Vista previa Explorador de tablas Vista previa Estadísticas Linaje Perfil de datos Calidad de l

Fila	card_id	user_id	iban	pan	pin	cvv
1	CcU-4688	25	IS383255756743611896271082	347635882232257	3159	350
2	CcU-4835	4	PT34592171131763200132583	3723 677744 22550	1149	680
3	CcU-4478	55	SI52116155174087513	5451685219226844	3161	939
4	CcU-4163	100	SE7951484302898821300669	4556 776 96 5734	7098	953
5	CcU-3680	169	MD4799721070815687888150	5426 4337 3314 6889	8556	690
6	CcU-3155	244	AD2777204763277722050982	4532263578421	3015	779
7	CcU-4443	60	BH44392039643136345028	491 65266 67312 570	2283	141
8	CcU-3120	249	RS72655766666166237144	527646 533375 6577	7658	265
9	CcU-3127	248	PT83533461438644342816864	4716 443 46 4368	8038	924
10	CcU-3918	135	NO4414757761220	5567675343638684	5616	230
11	CcU-3603	180	IT166ASAB181164333755123881	376495785724718	3355	862
12	CcU-3764	157	DO8323918488352565612425...	535 23847 59612 247	6546	194
13	CcU-3323	220	BG05UBIX63820348156559	4716 5927 4626 2576	8319	860
14	CcU-4646	31	CR7237735131501258248	4485 8278 9259 2981	1686	987
15	CcU-3099	252	PT26105275356823705537218	448 55418 98863 789	5612	564
16	CcU-3393	210	VG1468087984174645729577	4338 849 61 6580	7375	763
17	CcU-3463	200	RS35935488614486812686	4485654846578	7658	260
18	CcU-3386	211	HR9310391623647587418	375233562287679	7448	433
19	CcS-7490	2909	XX615598489362166929813228	2107282408581708	8533	602

Nivell 3: Presentació de Dades i Creació de Vistes

Escenari:

Al nivell anterior vas actuar com a Data Engineer netejant les dades (`_clean`). Ara toca posar-se el barret d'Analista de Negoci. El problema actual és que les taules estan separades i algunes tenen formats difícils d'exploitar (com la llista de productes comprimida en una sola cel·la). En aquest nivell crearàs **Vistes** per facilitar l'accés a la informació i generaràs informes finals.

» Objectius:

- » Crear Vistes (CREATE VIEW) per encapsular lògica de negoci complexa.
- » Resoldre el repte de dades agrupades en strings (SPLIT + UNNEST).
- » Exportar resultats per a tercers (Reverse ETL).

Exercici 1: La Vista de Màrqueting (Lògica de Negoci)

Màrqueting necessita segmentar els clients corporatius, però no saben fer JOINS. La teva tasca és deixar-los la informació preparada.

» Tasca:

Crea una vista anomenada `sprint3_gold.v_marketing_kpis` que mostri la següent informació per a cada companyia:

- » **Nom de la companyia, Telèfon i País** (origen: `companies_clean`).
- » **Mitjana de compra** (AVG(amount) de `transactions_clean`).
- » **Classificació de Client (Lògica)**:

Crea una columna calculada anomenada `client_tier`.

Si la mitjana de compra és superior a **260€**, etiqueta com a **"Premium"**.


Si és igual o inferior, etiqueta com a **"Standard"**.

En aquest exercici es construeix una vista en el *dataset* `sprint3_gold` que encapsula la lògica de negoci necessària perquè l'equip de Màrqueting pugui consultar informació sense necessitat de fer JOINS ni càlculs. La vista combina les dades mestres de les companyies amb les transaccions i calcula la mitjana de compra per empresa. A partir d'aquesta mitjana es defineix una classificació de client que permet segmentar-los en "Premium" o "Standard".

S'utilitza `ROUND` perquè les bones pràctiques -incloses les de la ITAcademy- indiquen que qualsevol mètrica monetària s'ha de normalitzar a dos decimals. BigQuery calcula les mitjanes amb tipus `FLOAT64` i pot generar valors amb molts decimals, així que aplicar `ROUND(..., 2)` garanteix consistència i coherència en la presentació de les dades.

Tot aquest procés queda integrat dins la vista, de manera que els usuaris finals només han de consultar-la per obtenir els indicadors ja preparats. Finalment, es realitza una consulta ordenada per prioritzar els clients Premium i, dins d'aquests, els que tenen una mitjana de compra més elevada.

Dit això, carreguem la sentència:



```
1 create or replace view `sprint3-analytics-bieldomenech.sprint3_gold.v_marketing_kpis` as
2 select c.company_name as Nom_Empresa,
3        c.phone as Telefon,
4        c.country as Pais,
5        round(avg(t.amount),2) as Preu_Mitja,
6        case when avg(t.amount) > 260 then 'Premium'
7        else 'Standard'
8        end as Nivell_Client
9 from `sprint3-analytics-bieldomenech.sprint3_silver.companies_clean` as c
10 left join `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as t
11 on c.company_id = t.business_id and t.declined = 0
12 group by c.company_name, c.phone, c.country;
13
```

Esta consulta procesará 0 B cuando se ejecute.

El procés finalitza amb el següent resultat:

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Consulta sin título

Ejecutar

Guardar

Descargar

Compartir

```
1 create or replace view `sprint3-analytics-bieldomenech.sprint3_gold.v_marketing_kpis` as
2 select c.company_name as Nom_Empresa,
3 c.phone as Telefon,
4 c.country as Pais,
5 round(avg(t.amount),2) as Preu_Mitja,
6 case when avg(t.amount) > 260 then 'Premium'
7 else 'Standard'
8 end as Nivell_Client
9 from `sprint3-analytics-bieldomenech.sprint3_silver.companies_clean` as c
10 left join `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as t
11 on c.company_id = t.business_id and t.declined = 0
12 group by c.company_name, c.phone, c.country;
13
14
```

Se completó la consulta

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

Esta declaración creó una nueva vista llamada v_marketing_kpis.

Validem que s'ha creat la vista:

- ▼ sprint3-analytics-bieldomenech
 - ▶ Repositorios
 - ▶ Consultas
 - ▶ Notebooks
 - ▶ Lienzos de datos
 - ▶ Preparaciones de datos
 - ▶ Canalizaciones
 - ▶ Conexiones
 - ▶ sprint3_bronze
 - ▼ sprint3_gold
 - v_marketing_kpis
 - ▶ sprint3_silver

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I validarem els camps que mostrarà la vista des de **Esquema**:

sprint3-analytics-bieldomenech / Datasets / sprint3_gold / Tables / v_marketing_kpis

☆ v_marketing_kpis Consulta Chat Abrir en ▾ + Compartir ▾

Esquema Detalles Explorador de tablas **Vista previa** Estadísticas Linaje

Filtro Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Inter
☐	Nom_Empresa	STRING	NULLABLE	-	-	-
☐	Telefon	STRING	NULLABLE	-	-	-
☐	Pais	STRING	NULLABLE	-	-	-
☐	Preu_Mitja	FLOAT	NULLABLE	-	-	-
☐	Nivell_Client	STRING	NULLABLE	-	-	-

» Entrega:

Realitza una consulta SELECT * sobre la teva nova vista, ordenant els resultats perquè apareguin primer els clients "Premium" i, dins d'aquests, els que tinguin major mitjana de compra.

La consulta final mostra totes les companyies de la vista i ordena els resultats perquè els clients classificats com a Premium apareguin primer. Dins d'aquest grup, els resultats s'ordenen per la mitjana de compra de manera descendent:

Consulta sin título Ejecutar Guardar ▾ Descarga

```
1 select *
2 from `sprint3-analytics-bieldomenech.sprint3_gold.v_marketing_kpis`
3 order by Nivell_Client, Preu_Mitja desc;
```

✓ Esta consulta procesará 2.29 MB cuando se ejecute.

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

I aquest son els resultats obtinguts:

Consulta sin titulo

Ejecutar

Guardar

Descargar

Compartir

Programa

Abrir en

```
1 select *
2 from `sprint3-analytics-bieldomenech.sprint3_gold.v_marketing_kpis`
3 order by Nivell_Client, Preu_Mitja desc;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Chat Guardar los resultados

Información del trabajo

Resultados

Visualización

JSON

Detalles de la ejecución

Gráfico de ejecución

Fila	Nom_Empresa	Telefon	Pais	Preu_Mitja	Nivell_Client
1	Ac Fermentum Incorporated	06 85 56 52 33	Germany	284.91	Premium
2	Pretium Neque Corp.	07 77 48 55 28	Australia	275.58	Premium
3	Urna Convallis Associates	06 01 24 77 04	United States	273.57	Premium
4	At Associates	09 56 61 10 65	New Zealand	272.74	Premium
5	Metus Vitae Associates	08 25 44 40 66	Australia	270.05	Premium
6	Aliquet Diam Limited	02 76 61 47 46	United States	269.29	Premium
7	Nec Luctus LLC	02 14 71 75 73	Norway	268.6	Premium
8	Neque Tellus Incorporated	04 43 18 34 19	Ireland	267.56	Premium
9	Cras Consulting	07 50 10 85 63	Belgium	267.38	Premium
10	Sed LLC	01 63 16 26 52	Belgium	266.61	Premium

Resultados por página: 50 1 - 50 de 100

Exercici 2: Rànquing de Productes (La Potència dels Arrays)

Escenari de Negoci:

L'equip de vendes vol optimitzar el catàleg. Necessiten un informe a la capa Gold que mostri el rendiment real de cada producte. Gràcies a la teva bona enginyeria a la capa Silver, la taula `transactions_clean` ja té els IDs de producte perfectament organitzats en una llista (Array). Ara toca explotar aquesta estructura.

» Objectiu:

Crea la taula `sprint3_gold.product_sales_ranking` que contingui l'inventari complet de productes i quantes vegades s'ha venut cadascun.

» Requisits de l'Informe:

» **Detall del Producte:** Ha d'incloure `product_id`, `name`, `price` i `color` (vénen de la taula `products_clean`).

» **Mètrica de Negoci:** Una columna nova `total_sold` que compti quantes vegades apareix aquest producte a les transaccions.

» **Integritat:** Han d'aparèixer tots els productes, fins i tot els que tenen 0 vendes (potser cal descatalogar-los).

» Pista Tècnica:

» A `transactions_clean`, els productes estan "encapsulats" dins d'un Array per cada transacció.

» Primer necessitaràs "aplanar" la taula de transaccions usant `UNNEST(product_ids)` per poder comptar els productes individualment.

» Després, fes un encreuament (`LEFT JOIN`) començant per la taula de productes per no perdre aquells que no s'han venut mai.

Ara la taula `transactions_clean` del *dataset* `sprint3_silver` mostra el camp `product_ids` amb tipus `STRING`. Aquest format no permet utilitzar la funció `UNNEST` al *dataset* `sprint3_gold`, ja que BigQuery només pot desanidar col·leccions quan el camp és un `ARRAY`. Per aquest motiu, és necessari normalitzar aquest camp dins del *dataset* `sprint3_silver`.

En el fitxer original, `product_ids` apareix com una cadena de text amb valors separats per comes (per exemple, "81, 94, 95, 66, 64"). Aquest format no és adequat per al model analític, perquè no permet treballar amb cada producte de manera individual. Per resoldre-ho, es reconstrueix la taula `transactions_clean` a

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

partir de la taula `transactions_raw`, aplicant una transformació que divideix la cadena en elements individuals amb `split(product_ids, ',')`, elimina els espais sobrants amb `trim(id)` i converteix cada element a enter amb `cast(... as int64)`. Finalment, aquests valors es tornen a agrupar en un `ARRAY<INT64>`.

Aquesta normalització garanteix que `product_ids` queda tipat correctament i preparat per a qualsevol càlcul posterior. A partir d'aquest punt, és possible utilitzar `UNNEST(product_ids)` de manera directa i eficient al *dataset* `sprint3_gold`, sense necessitat de conversions addicionals. D'aquesta manera, el *dataset* `sprint3_silver` compleix el seu objectiu de proporcionar dades netes, consistents i preparades per a l'anàlisi.

A continuació es mostra la sentència utilitzada per reconstruir la taula `transactions_clean` amb el camp `product_ids` ja normalitzat:

```
Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir]
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as
2 select id as transaction_id, amount, timestamp, lat, longitude, card_id, business_id, user_id,
3 declined,
4 array(
5   select cast(trim(id) as int64)
6   from unnest(split(product_ids, ',')) id
7 ) as product_ids
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
9

✓ Esta consulta procesará 0 B cuando se ejecute.
```

I aquest és el resultat del canvi de tipus del camp `product_ids`:

```
Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir]
1 create or replace table `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as
2 select id as transaction_id, amount, timestamp, lat, longitude, card_id, business_id, user_id,
3 declined,
4 array(
5   select cast(trim(id) as int64)
6   from unnest(split(product_ids, ',')) id
7 ) as product_ids
8 from `sprint3-analytics-bieldomenech.sprint3_bronze.transactions_raw`;
9

✓ Se completó la consulta
```

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

❗ Esta declaración reemplazó la tabla denominada transactions_clean.

Ara que la taula `transactions_clean` ja té el camp `product_ids` en el format correcte (`ARRAY<INT64>`), podem treballar amb cada producte de manera individual. Aquesta transformació és important perquè ens permet “desfer” la llista de productes que hi havia dins de cada transacció i convertir-la en files separades. D'aquesta manera, cada producte venut es pot comptar de forma independent.

Amb aquesta base ja preparada al *dataset* `sprint3_silver`, podem construir la taula `product_sales_ranking` al *dataset* `sprint3_gold`. L'objectiu és saber quantes vegades s'ha venut cada producte i obtenir un rànquing clar i fàcil d'interpretar.

Per fer-ho, primer “aplanem” el camp `product_ids` amb la funció `UNNEST()`, que converteix cada producte en una fila. Aquest pas es col·loca dins d'un CTE per separar-lo de la resta de la consulta i fer-la més llegible.

Després, fem un `LEFT JOIN` amb la taula `products_clean` per assegurar que tots els productes apareguin al

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

resultat, fins i tot aquells que no han tingut cap venda. Finalment, comptem quantes vegades apareix cada producte i guardem aquesta informació a la taula final.

Dit tot això, carreguem la consulta:

```
Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir] [Programa] [Abrir en]

1 create or replace table `sprint3-analytics-bieldomenech.sprint3_gold.product_sales_ranking` as
2 with transacciones_apanadas as (
3   select id as product_id
4   from `sprint3-analytics-bieldomenech.sprint3_silver.transactions_clean` as t
5   cross join unnest(t.product_ids) as id
6 )
7
8 select p.product_id as Producte_id, p.name as Nom, p.price as Preu, p.colour as Color, count(e.product_id) as total_venut
9 from `sprint3-analytics-bieldomenech.sprint3_silver.products_clean` as p
10 left join transacciones_apanadas as e
11 | on p.product_id = e.product_id
12 group by p.product_id, p.name, p.price, p.colour;
13
```

✓ Esta consulta procesará 1.94 MB cuando se ejecute.

I aquest és el resultat de l'execució, on es confirma la creació de la taula:

Consulta sin título [Ejecutar] [Guardar] [Descargar] [Compartir]

1 create or replace table `sprint3-analytics-bieldomenech.sprint3\_gold.product\_sales\_ranking` as
2 with transacciones_apanadas as (
✓ Se completó la consulta


Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo Resultados Detalles de la ejecución Gráfico de ejecución

❗ Esta declaración reemplazó la tabla denominada product_sales_ranking.

Confirmem la creació de la taula:



I validem el contingut de la taula, tant amb l'opció **Esquema** com amb **Vista previa**:

sprint3-analytics-bieldomenech / Datasets / sprint3_gold / Tables / product_sales_ranking

☆ product_sales_ranking 🔍 Consulta 💬 Chat 📄 Abrir en ▾ 👤 Compartir

Esquema Detalles Vista previa Explorador de tablas **Vista previa** Estadísticas

☰ Filtro Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave	Interca
☐	Producte_id	INTEGER	NULLABLE	-	-	-
☐	Nom	STRING	NULLABLE	-	-	-
☐	Preu	FLOAT	NULLABLE	-	-	-
☐	Color	STRING	NULLABLE	-	-	-
☐	total_venut	INTEGER	NULLABLE	-	-	-

sprint3-analytics-bieldomenech / Datasets / sprint3_gold / Tables / product_sales_ranking

☆ product_sales_ranking 🔍 Consulta 💬 Chat 📄 Abrir en ▾ 👤 Compartir ▾ 📄 C

Esquema Detalles **Vista previa** Explorador de tablas **Vista previa** Estadísticas Linaje

Fila	Producte_id	Nom	Preu	Color	total_venut
1	80	Tarly Stark	14.1	#020202	2496
2	40	tatooine dooku solo	73.31	#070707	2488
3	32	north	178.28	#0f0f0f	2561
4	29	Tully maester Tarly	167.2	#111111	2635
5	4	warden south duel	71.89	#111111	2584
6	11	Karstark Dorne	49.7	#141414	2573
7	86	Stark kingsblood	189.21	#141414	2528
8	33	duel warden	127.09	#191919	2597
9	67	Winterfell	195.94	#1c1c1c	2552
10	99	the duel	151.78	#212121	2514
11	51	north Tully	30.14	#262626	2466
12	96	dooku solo	20.92	#282828	2506
13	46	giantsblood maester Karstark	58.78	#2b2b2b	2513
14	25	skywalker ewok	157.53	#2b2b2b	2521
15	58	solo palpatine chewbacca	130.59	#2b2b2b	2567
16	13	palpatine chewbacca	139.59	#2b2b2b	2560
17	68	Stark Karstark	167.37	#333333	2589
18	84	Karstark Tully Dorne	92.91	#353535	2545
19	8	Winterfell	32.37	#383838	2503
20	53	kingsblood Littlefinger the	137.81	#3a3a3a	2564

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Exercici 3: Exportació de Resultats


El teu mànager no té accés a BigQuery i vol el llistat de "Top Productes" en un Excel per a una reunió.

» Tasca:


Exporta les dades de la taula `product_sales_ranking` a **Google Sheets** o baixa l'arxiu **CSV** localment.

Com que BigQuery no permet descarregar directament una taula completa en local, el procés d'exportació es realitza executant un `SELECT *` sobre la taula `product_sales_ranking` i utilitzant l'opció d'exportació dels resultats. Aquesta opció permet descarregar el fitxer CSV directament a l'ordinador. Un cop descarregat, l'arxiu s'obre amb Excel per comprovar que les dades s'han exportat correctament.

A continuació es mostra la consulta utilitzada per obtenir totes les dades de la taula `product_sales_ranking`:



Un cop executada la consulta, BigQuery mostra els resultats que posteriorment s'exportaran:




Resultados de la consulta

Información del trabajo		Resultados	Visualización	JSON	Detalles de la ejecución	Gráfico de ejecu
Fila	Producte_id	Nom	Preu	Color	total_venut	
1	80	Tarly Stark	14.1	#020202	2496	
2	40	tatooine dooku solo	73.31	#070707	2488	
3	32	north	178.28	#0f0f0f	2561	
4	29	Tully maester Tarly	167.2	#111111	2635	
5	4	warden south duel	71.89	#111111	2584	
6	11	Karstark Dorne	49.7	#141414	2573	
7	86	Stark kingsblood	189.21	#141414	2528	
8	33	duel warden	127.09	#191919	2597	
9	67	Winterfell	195.94	#1c1c1c	2552	
10	99	the duel	151.78	#212121	2514	
11	51	north Tully	30.14	#262626	2466	
12	96	dooku solo	20.92	#282828	2506	

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

A continuació es mostra el procés d'exportació dels resultats a un fitxer CSV en local, al clicar en l'opció **Guardar los resultados**:



L'arxiu es descarrega automàticament:

Recent download history




bquxjob_6b17cb10_19e03b45946.csv
3.7 KB • Done

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

» Entrega:

Una captura de pantalla on es vegi l'arxiu obert (Excel/Sheets) amb les dades correctament formatades.

Finalment, aquest és l'arxiu CSV obert amb Excel, on es poden veure les dades correctament exportades i llegibles:



	A	B	C	D	E
	Producte_id	Nom	Preu	Color	total_venut
1	52	riverlands the duel	31.52	#727272	2654
2	29	Tully maester Tarly	167.2	#111111	2635
3	21	duel Direwolf	96.9	#e2e2e2	2609
4	16	the duel warden	180.91	#666666	2608
5	66	mustafar jinn	2.12	#545454	2601
6	87	sith Jade	96.26	#e2e2e2	2598
7	33	duel warden	127.09	#191919	2597
8	48	rock Renly in	21.53	#9e9e9e	2597
9	23	riverlands north	169.96	#545454	2593
10	68	Stark Karstark	167.37	#333333	2589
11	88	Stannis warden south	167.15	#515151	2587
12	4	warden south duel	71.89	#111111	2584
13	73	Dorne bastard	114.09	#848484	2584
14	28	chewbacca mustafar	127.44	#efefef	2584
15	31	Lannister	85.02	#3f3f3f	2580
16	34	of north	128.48	#919191	2580
17	38	ewok sith	55.43	#666666	2578
18	61	Winterfell Lannister	28.01	#848484	2575
19	36	Lannister	96.22	#a5a5a5	2575
20	54	dooku solo	13.14	#e5e5e5	2575
21	24	south duel tourney	48.99	#aaaaaa	2574
22	11	Karstark Dorne	49.7	#141414	2573
23	72	north	161.6	#474747	2573
24	2	Tarly Stark	9.24	#919191	2573
25	47	Tully	82.15	#919191	2571
26	39	warden	196.65	#a0a0a0	2571
27	10	Karstark Dorne	119.52	#f4f4f4	2571
28	74	duel warden	158.29	#707070	2569
29	64	Direwolf	195.62	#b7b7b7	2568
30	58	solo palpatine chewbacca	130.59	#2b2b2b	2567
31	65	riverlands the	121.91	#6b6b6b	2567
32	53	kingsblood Littlefinger the	137.81	#3a3a3a	2564
33	7	north of Casterly	63.33	#b7b7b7	2563
34	98	Direwolf Littlefinger	38.33	#bababa	2562
35	32	north	178.28	#0f0f0f	2561
36	13	palpatine chewbacca	139.59	#2b2b2b	2560
37	82	kingsblood Littlefinger the	12.45	#545454	2560
38	12	duel Direwolf	181.6	#a8a8a8	2558
39	67	Winterfell	195.94	#1c1c1c	2552
40	18	Karstark warden	148.91	#c4c4c4	2552
41	44	Karstark Dorne	105.48	#878787	2550